ROIG Mathieu

ENSAE 2ème année
Stage d'application
Année scolaire 2024–2025

Etude de politique monétaire par utilisation d'embeddings sur les discours de la Fed et du Congrès

Ecole Polytechnique
Paris

Maître de stage : Alessandro RIBONI
Juin 2025 – Septembre 2025

ENSAE Paris TSA 26644 www.ensae.fr
Service des relations entreprises et des stages
5, avenue Henry Le Chatelier — 91164 PALAISEAU CEDEX — FRANCE
Tél. : +33 (0)1 70 26 67 39 Courriel : stages@ensae.fr

Table des matières

1 Introduction **2**

2 Etude des discours de la Fed **3**
2.1 Sujet de l'étude . . . 3
2.2 Utilisation de Word embeddings . . . 3
2.3 Utilisation de SBERT . . . 3
2.4 Limitation de SBERT . . . 4
2.5 Intervention de Mistral . . . 5
2.6 Une alternative : doc2vec . . . 5
2.7 Resultats préliminaires . . . 5
2.8 Resultats . . . 6
2.9 Finetuning de SBERT . . . 8
2.10 Etude économétrique . . . 9
2.10.1 Lien entre influence et expérience . . . 9
2.10.2 Lien entre dissidence et diversité intra-réunion . . . 11
2.11 Conclusion étude de la Fed . . . 14

3 Etude des discours du Congrès des Etats-Unis **15**
3.1 Sujet de l'étude . . . 15
3.2 Interprétation par contexte : 2 approches différentes . . . 15
3.3 Première méthode : la méthode A La Carte . . . 15
3.3.1 Principe . . . 15
3.3.2 Implémentation . . . 17
3.3.3 Résultats - Plus Proches Voisins . . . 17
3.3.4 Résultats - Régression linéaire . . . 20
3.4 Deuxième méthode : Neural Network . . . 22
3.4.1 Principe . . . 22
3.4.2 Résultats . . . 22
3.5 Poursuite de la méthode A La Carte . . . 25
3.5.1 Evolution de la norme de β . . . 25
3.5.2 Corrélation avec indices boursiers . . . 26
3.6 Analyse locale de sentiments avec FinBERT . . . 28
3.7 Conclusion étude du Congrès . . . 29

4 Conclusion **30**

5 Bibliographie **31**

6 Annexes **32**

1 Introduction

L'objectif de ce document est de restituer l'ensemble des méthodes qui ont été vues lors de mon stage d'application de 2ème année à l'ENSAE Paris, au CREST, sous la supervision de Monsieur Alessandro Riboni.

Il y'a eu deux projets principaux, d'abord un travail concernant **la Banque Centrale des Etats-Unis** (Fed), en particulier l'étude des transcripts des réunions du FOCM pour répondre à la question suivante : "**Peut-on déterminer rigoureuseument si certaines personnes sont plus influentes que d'autres à partir des transcripts des réunions ?**". Le coeur du projet consistera à établir des mesures de similarité permettant de déduire l'influence des participants.
Le second projet concerne l'étude de discours du **Congrès des Etats-Unis**, avec pour objectif d'étudier la question suivante "**Peut-on mesurer rigoureusement la dissidence au sein du Congrès entre partis sur la Fed ?**". L'étude cherchera à déterminer comment les Républicains et les Démocrates considèrent la Fed, et comment mesurer la différence entre ces 2 relations bilatérales : Républicains/Fed et Démocrates/Fed.

Les 2 sujets seront détaillés davantage dans leur introductions respectives, ils ont néanmoins la même démarche scientifique : on récupère les transcripts des réunions publiés en accès libre (sur le site de Harvard ou Stanford) puis on utilise des méthodes d'embeddings sur ces discussions pour mesurer des phénomènes ou vérifier des hypothèses.

Bien que les 2 projets utilisent des méthodes de NLP pour produire les embeddings, une différence fondamentale doit être faite et sera rappelée plus tard. Dans le premier projet sur les discussions de la Fed, on va chercher à comparer des textes entre eux, on va pour cela utiliser des **Transformers**, outils relativement récents (2019) et au coeur de la recherche scientifique en NLP. En revanche pour le second projet, on va reprendre et poursuivre la méthode d'un article de Cambridge (2023) utilisant des **méthodes d'embeddings statitiques** plus anciennes (2013) afin d'avoir des **espaces d'embeddings de référence**, ce qui est plus compliqué à faire avec des Transformers.

Ainsi, les 2 sujets sont complémentaires. Le premier sujet permet d'**explorer les possibilités et utilisations des Transformers**, en particulier de leurs versions les plus récentes (2019 avec *SBERT* et 2023 avec *Mistral 7B Instruct*). Au contraire le second sujet utilise des **méthodes plus anciennes pour combler certaines failles** que présentent les dernières versions des Transformers.

Un détail important quant on en vient à travailler avec des Transformers est la **puissance de calcul**. En effet on va avoir besoin de traiter de grandes quantités de données au vu des datasets utilisés dans un temps raisonnable, ce qui dépend directement de la machine où est réalisée les calculs. Toute la suite du travail aurait été impossible en travaillant en local sur mon NVIDIA GT 630 (2 GO) mais devient possible sur le sspcloud de l'ENSAE avec une NVIDIA Tesla T4 (15 GO).

2 Etude des discours de la Fed

2.1 Sujet de l'étude

On va s'intéresser aux transcripts des réunions du **Federal Open Market Committee** (FOCM), l'organe de politique monétaire de la Reserve Fédérale (Banque Centrale des Etats-Unis). Ces transcripts de réunions sont publiés avec **5 ans de retard** mais offrent une restitution intégrale des discussions internes entre membres du comité, présentant alors les arguments économiques qui ont guidé les débats à l'époque.

La FOCM est l'organe de la Fed en charge de la politique monétaire des Etats-Unis, elle prend des décisions concernant la **gestion des taux d'intérêt** et l'offre de monnaie afin de poursuivre les 3 objectifs fixés par le Congrès américain : plein emploi, stabilité des prix, taux d'intérêts à long terme modérés (voir annexe sur hawkish vs dovish).

L'objet de notre travail va être de **mesurer l'influence des différents intervenants dans les discours**. Ce travail s'inscrit dans la poursuite de l'étude menée par le stagiaire précédent et vise à tester la robustesse de ses résultats. La base de données compte les discours de 1976 à 2018, dans un fichier csv de 150000 lignes pour 100 MO.

L'influence a été définie par la capacité à introduire des **idées novatrices**, qui n'apparaissent pas dans les discours précédents, et qui **deviennent des sujets de discussion par la suite**. On rapproche davantage cette définition à de la résonance qu'à de la persuasion.

La méthode utilisée par le précédent stagiaire était de faire du TF-IDF, légèrement modifiée pour prendre en compte une dimension temporelle dans les prises de parole (voir annexe sur la méthode TF-IDF).
Le principe était le suivant, on définit une liste de mots W contenant tous les mots de la discussion, après avoir filtré les mots trop fréquents ou trop rares.

On représente ensuite les prises de parole par un vecteur de taille W où chaque coordonnées représente l'importance d'un mot précis.

On peut alors faire un produit scalaire entre une prise de parole d'un individu, et toutes les prises de paroles au sein d'un meeting.

En comparant avec les meetings précédents, on peut voir si il introduit des **idées novatrices, donc un produit scalaire faible**, puis avec les meetings suivants si ses **idées sont reprises, donc un produit scalaire élevé**.

2.2 Utilisation de Word embeddings

L'objectif est de vérifier les résultats de la méthode TF-IDF utilisée pour de la mesure de similarité. Pour ça, le **word embeddings** est particulièrement adapté puisque le principe est de **représenter un mot par un vecteur**, ce qui permet facilement la manipulation de **produit scalaire**.

En plus, par rapport à l'approche TF-IDF où on prend seulement la fréquence du mot dans un discours pour lui associer une valeur, une approche par word embeddings peut permettre de prendre en compte également le **contexte de la phrase** pour comprendre le mot (exemple du mot basse, instrument de musique et contraire de haut).

2.3 Utilisation de SBERT

Pour faire du word embeddings, on ne peut pas passer à côté de **BERT** (Bidirectional Encoder Representations from Transformers), le transformer développé par Google en 2018. Il a révolutionné la manière dont

les machines comprennent le texte, en tenant compte du contexte à droite et à gauche d'un mot.

Ainsi, BERT fait du word embeddings contextuel, c'est à dire qu'au lieu de modèle plus ancien comme word2vec qui attribue pour chaque mot un vecteur indépendemment de son contexte, **BERT ajuste la valeur de chaque mot spécifiquement à son contexte**.

Bien que BERT puisse s'utiliser en zero shot, ici le jargon des textes étant très resséré autour de l'économie, la question méritera d'être posée sur la nécessité ou non de fine-tuner le modèle.

Pour être plus précis, on ne va pas utiliser BERT qui permettrait de vectoriser mot à mot mais plutôt **SBERT**, Sentence-BERT (all-MiniLM-L6-v2), sa version adaptée pour des représentations vectorielles de phrases. C'est à dire qu'avec SBERT, **2 phrases dont le sens est similaire auront des vecteurs de coordonnées proches dans l'espace**.

Grossièrement, **SBERT = BERT + mean-pooling**, c'est à dire qu'on va encoder mot à mot puis faire la moyenne des mots de la phrase pour représenter la phrase sous un vecteur. L'entrainement de SBERT est également étudié pour mieux prendre en compte la mesure de similarité, que ne l'est BERT qui n'est pas vraiment conçu pour ça.

NB : il est théoriquement possible de faire la même chose avec word2vec : d'encoder mot à mot puis de faire la moyenne, cependant les résultats sont de bien plus faible qualité car word2vec n'est pas prévu pour ça, au contraire de SBERT (voir benchmark en ligne).

2.4 Limitation de SBERT

La première difficulté à l'utilisation de SBERT dans notre étude est sa **limite d'entrée de tokens**.

SBERT a une **limite de 512 tokens en input**, ce qui équivaut à 300 mots environ. Or, lorsqu'on s'intéresse à la prise de parole la plus longue, on est largement au dessus (5642 tokens). Encore pire, lorsqu'on s'interesse à un meeting en entier, on compte en moyenne 400 interventions successives au cours du même meeting.

Une première piste a été de suivre le principe du passage de BERT à SBERT : pour vectoriser un texte, on va vectoriser phrase à phrase puis en faire la moyenne.

On peut vectoriser 700k phrases en moins de 2h en travaillant avec une NVIDIA 630 ou une dizaine de minutes avec une NVIDIA récente. Cependant, on se rend compte qu'une simple moyenne des différents vecteurs est une approche bien trop simpliste, on n'accorde pas davantage de poids aux idées importantes, ce qui fait qu'on noie totalement les informations clés dans un vecteur qui pointera plus ou moins dans la même direction pour tout le monde.

Alors, une seconde piste pour contourner la limitation serait de résumer les prises de paroles trop longues. Seulement, on risque de comparer des phrases de quelques mots à des phrases résumées avec toutes les idées principales.

L'idée sera alors la suivante : **au sein d'un meeting, on garde seulement la prise de parole la plus longue par individu, qu'on va demander à un LLM de résumer en 512 tokens maximum, pour pouvoir faire un embedding dessus avec SBERT**.

2.5 Intervention de Mistral

Un des LLM les plus populaires est celui développé par Meta : BART-large-CNN. Or pour le choix de notre LLM, on doit tenir compte de la limite d'entrée du modèle. Ce dernier n'accepte que 1024 tokens maximum, ce qui est bien inférieur à nos prises de parole les plus longues.

Une solution aurait pu être de recourir à du **chunking**, c'est à dire de découper le texte lorsqu'il dépasse la limite de BART en sous-textes, de résumer ces derniers puis d'aggréger les résumés en un résumé final qui serait sous 512 tokens. Cette solution a été mise de côté quant à la qualité des résumés finaux.

En revanche, une alternative qui a fourni de meilleurs résumés était en utilisant **Mistral-7B-Instruct-v0.2**. Ce LLM développé par Mistral en libre accès sur Hugging Face compte plus de 7 milliards de paramètres, et **peut prendre un prompt en entrée**. Cette fonctionnalité est utile puisque si on veut faire notre étude de similarité, il faut être sûr que le résumé fourni sera d'un style similaire à ceux des interventions non résumées (celles ne dépassant pas la limite d'embedding des 512 tokens).

2.6 Une alternative : doc2vec

Une autre piste pour réaliser un embedding des interventions des individus au sein des meetings a été l'étude de doc2vec, une extension réalisée en 2014 de word2vec pour apprendre des représentations vectorielles de textes entiers.

Cette méthode est **bien moins performante que SBERT car elle ne capte pas les relations syntaxiques profondes, et ne profite ni de self-attention ni de bidirectionnalité**. En revanche, **sa simplicité et sa rapidité de calcul** lui donne le mérite d'avoir été prise en compte.

2.7 Resultats préliminaires

Etant donné la taille de la base de données des 358 meetings à disposition, on va étudier 3 meetings successif pris au hasard pour vérifier qu'on obtient des résultats cohérents, prenons les dates : **2005-02-02, 2005-03-22, 2005-05-03** qui comptent 686 interventions.

Lorsqu'on ne prend que la déclaration la plus longue par individu, et qu'on ne s'interesse qu'aux membres de la FOCM, il ne reste que 55 interventions.

Après une lecture des 3 meetings, on peut s'attendre à voir figurer dans le top 3 : **Mr. Greenspan** le président de la Fed au moment du meeting, **Mr. Bernanke** le successeur de Greenspan à la place de président, et **Mr. Geithner** avec des remarques particulièrement denses, novatrices et qui anticipent des tensions futures.

Nous allons mesurer les résultats suivants pour chaque individu :

- **Le score FS** (Forward Similarity) : il correspond à la moyenne des produits scalaires entre le vecteur de sa déclaration la plus longue lors d'un meeting et chacun des vecteurs des déclarations les plus longues du meeting suivant.
- **Le score BS** (Backward Similarity) : il correspond à la moyenne des produits scalaires entre le vecteur de sa déclaration la plus longue lors d'un meeting et chacun des vecteurs des déclarations les plus longues du meeting précédent.
- **L'influence** : elle est définie comme le rapport des deux mesures précédentes, soit :

$$\text{Influence} = \frac{\text{FS}}{\text{BS}}$$

Pour chaque individu, nous reportons la moyenne de ses résultats sur l'ensemble des meetings.

Avec doc2vec, on obtient les résultats suivants :

Top Influence Speaker	**Infl.**	**FS**	**Top FS Speaker**	**Infl.**	**FS**	**Top BS Speaker**	**Infl.**	**BS**
MS. YELLEN	1.0037	0.9981	MR. STERN	1.0021	0.9993	MR. GREENSPAN	1.0013	0.9976
MR. SANTOMERO	1.0030	0.9989	MS. BIES	1.0027	0.9992	MR. FERGUSON	1.0011	0.9974
MS. HOLCOMB	1.0030	0.9990	MR. BERNANKE	1.0026	0.9992	MR. OLSON	1.0018	0.9974
MR. KOHN	1.0029	0.9988	MR. GUYNN	1.0027	0.9992	MR. STERN	1.0021	0.9972
MR. MOSKOW	1.0029	0.9991	MR. OLSON	1.0018	0.9991	MR. GEITHNER	1.0020	0.9971

TABLE 1 – doc2vec : Top 5 des métriques d'influence, de similarité future (FS), et de similarité passée (BS)

Les résultats sont peu concluants, **les scores de BS et FS sont proches à 10-4 près**, ce qui peut suggérer que le classement se joue à un mot ou à une phrase près.

Doc2vec a une capacité limitée à capter les subtilités sémantiques fines, surtout entre des textes d'un même domaine, avec ici des textes uniquement discutant d'économie. Une solution pourrait être d'augmenter la quantité de données afin de voir si plus de différences sont faites.

Avec l'alliance de SBERT et de Mistral :

Top Influence Speaker	**Infl.**	**FS**	**Top FS Speaker**	**Infl.**	**FS**	**Top BS Speaker**	**Infl.**	**BS**
MR. POOLE	1.2219	0.5206	MS. PIANALTO	1.1015	0.6157	MR. HOENIG	1.0490	0.5747
MR. LACKER	1.1978	0.5106	MR. HOENIG	1.0490	0.6029	MR. GEITHNER	1.0293	0.5681
MS. MINEHAN	1.1840	0.5117	MR. GEITHNER	1.0293	0.5848	MS. PIANALTO	1.1015	0.5590
MS. HOLCOMB	1.1700	0.4208	MR. STERN	1.0879	0.5724	MR. FERGUSON	1.0384	0.5416
MR. GUYNN	1.1523	0.4478	MS. BIES	1.1305	0.5658	MR. STERN	1.0879	0.5262

TABLE 2 – SBERT et Mistral : Top 5 des métriques d'influence, de similarité future (FS), et de similarité passée (BS)

Les différences entre les interventions sont plus nettes avec cette méthode. Néanmoins, **la pertinence des résultats est à discuter**. Ici Mr.Greenspan n'apparait dans aucun des trois top5, ce qui reste peu probable pour le Chair en place.

2.8 Resultats

On va maintenant appliquer les 2 méthodes précédentes à **la base de données complète**. Pour rappel, la base de données complète est composée de 358 meetings, et en ne prenant que l'intervention la plus longue des membres de la FOCM, on se restreint à 6476 interventions.

On va également filtrer à partir de 1979 et prendre en compte seulement les membres qui ont plus de 12 meetings d'expérience.

On obtient pour Mistral (50h de résumé) et SBERT (5mins d'embedding) :

Top Influence Speaker	FS	BS	Infl.	Top FS Speaker	FS	BS	Infl.	Top BS Speaker	FS	BS	Infl.
MR. POWELL	0.4854	0.4665	1.0405	MR. SANTOMERO	0.5433	0.5485	0.9904	MR. SANTOMERO	0.5433	0.5485	0.9904
MS. RASKIN	0.4473	0.4347	1.0288	MS. PHILLIPS	0.5270	0.5283	0.9975	MR. GEITHNER	0.5243	0.5286	0.9919
MR. LOCKHART	0.4627	0.4522	1.0233	MR. GEITHNER	0.5243	0.5286	0.9919	MS. PHILLIPS	0.5270	0.5283	0.9975
MR. WINN	0.4381	0.4290	1.0212	MR. HOENIG	0.5189	0.5196	0.9987	MR. HOENIG	0.5189	0.5196	0.9987
MS. BRAINARD	0.4961	0.4861	1.0206	MR. KOHN	0.5162	0.5169	0.9986	MR. KOHN	0.5162	0.5169	0.9986
MR. LINDSEY	0.3939	0.3862	1.0199	MR. MOSKOW	0.5149	0.5168	0.9963	MR. MOSKOW	0.5149	0.5168	0.9963
MR. DUDLEY	0.3850	0.3791	1.0157	MR. STERN	0.5147	0.5135	1.0023	MR. KASHKARI	0.5124	0.5166	0.9919
MR. GREENSPAN	0.3243	0.3197	1.0144	MR. KASHKARI	0.5124	0.5166	0.9919	MR. BOSTIC	0.5078	0.5160	0.9842
MR. LAWARE	0.4735	0.4668	1.0143	MR. SYRON	0.5114	0.5152	0.9925	MR. SYRON	0.5114	0.5152	0.9925
MR. OLSON	0.4197	0.4143	1.0131	MR. KROSZNER	0.5083	0.5122	0.9924	MR. STERN	0.5147	0.5135	1.0023
MR. HELLER	0.4738	0.4678	1.0128	MR. GRAMLEY	0.5082	0.5032	1.0100	MR. KROSZNER	0.5083	0.5122	0.9924
MS. GEORGE	0.4833	0.4773	1.0125	MR. BOSTIC	0.5078	0.5160	0.9842	MR. GUYNN	0.5051	0.5089	0.9925

TABLE 3 – Mistral + SBERT : Top 12 des métriques d'influence, de similarité future (FS), et de similarité passée (BS) depuis 1979, filtré par expérience supérieure à 12 meetings.

Parmi les membres les plus influents, **on retrouve certaines figures historiques** comme Mr. Powell en première position, l'actuel président de la Fed depuis 2018, ou encore Mr. Greenspan qui l'a été de 1987 à 2006. D'autres noms viennent étayer le classement avec Ms. Brainard **mais certaines références** comme Mr. Volcker ou Mr. Bernanke **manquent à l'appel**.

NB : ici l'étape de résumer les déclarations (celles supérieures à 512 tokens) a pris plus de 50h, il est alors bien important de **définir un prompt de qualité** à fournir au LLM afin de ne pas avoir à lancer le code plusieurs fois.

Pour ce qui est de doc2vec (5 mins d'embedding) :

Top Influence Speaker	FS	BS	Infl.	Top FS Speaker	FS	BS	Infl.	Top BS Speaker	FS	BS	Infl.
MR. STEIN	0.1788	0.1488	1.2022	MR. EASTBURN	0.2719	0.2731	0.9958	MR. EASTBURN	0.2719	0.2731	0.9958
MR. POWELL	0.1815	0.1721	1.0545	MR. SCHULTZ	0.2482	0.2542	0.9767	MR. SCHULTZ	0.2482	0.2542	0.9767
MR. BLINDER	0.1330	0.1263	1.0536	MS. TEETERS	0.2434	0.2403	1.0131	MS. TEETERS	0.2434	0.2403	1.0131
MS. BIES	0.1411	0.1345	1.0490	MR. RICE	0.2381	0.2361	1.0087	MR. MAYO	0.2339	0.2399	0.9749
MR. KROSZNER	0.1786	0.1717	1.0404	MR. MAYO	0.2339	0.2399	0.9749	MR. ROOS	0.2287	0.2365	0.9671
MR. GRAMLICH	0.1368	0.1319	1.0378	MR. ROOS	0.2287	0.2365	0.9671	MR. RICE	0.2381	0.2361	1.0087
MR. LINDSEY	0.1125	0.1085	1.0375	MR. GRAMLEY	0.2234	0.2218	1.0072	MR. PARTEE	0.2206	0.2276	0.9694
MR. POOLE	0.1276	0.1230	1.0373	MR. PARTEE	0.2206	0.2276	0.9694	MR. GRAMLEY	0.2234	0.2218	1.0072
MR. JOHNSON	0.1965	0.1897	1.0361	MR. BALLES	0.2172	0.2173	0.9994	MR. WALLICH	0.2164	0.2200	0.9837
MR. FERGUSON	0.1532	0.1479	1.0357	MR. MORRIS	0.2172	0.2149	1.0105	MR. BALLES	0.2172	0.2173	0.9994
MR. DUDLEY	0.1577	0.1523	1.0349	MR. WALLICH	0.2164	0.2200	0.9837	MR. MORRIS	0.2172	0.2149	1.0105
MR. GREENSPAN	0.1260	0.1219	1.0342	MR. BOYKIN	0.2150	0.2138	1.0054	MR. SOLOMON	0.2126	0.2148	0.9899

TABLE 4 – Doc2vec : Top 12 des métriques d'influence, de similarité future (FS), et de similarité passée (BS) depuis 1979, filtré par expérience supérieure à 12 meetings.

Ici encore on a bien la **présence de certaines figures historiques** : Mr. Stein, Mr. Powell, Mr. Kroszner, Mr. Greenspan. Bien que **d'autres noms** tels que Mr. Volcker ou Mr. Burnanke **n'apparaissent toujours pas**, on a obtenu un **classement pertinent en seulement 5 minutes contre plusieurs jours avec Mistral et SBERT**, ce qui invite à s'interroger sur la nécessité de la précision de l'embedding sémantique.

On remarque par contre que le FS et le BS moyen n'a rien à voir avec celui de la partie précédente, les top FS et BS sont autour de 0.25 contre 0.999 précédemment. On en déduit que le choix des hyperparamètres dans la construction du modèle est décisif car ici la même taille de vecteur de sortie et le même nombre d'epochs ont été utilisés pour traiter des phrases de même longueurs, mais avec une quantité de données

environ 120x plus grande ce qui a sous doute produit un overfitting avant.

NB : **différence de pre-processing avant l'embedding entre doc2vec et SBERT** :

Avant d'utiliser doc2vec, on préférera mettre tout le texte en minuscule, retirer les stop words ou les mots très courts, retirer les discours de moins de 30 mots, retirer la ponctuation, potentiellement faire du stemming ou de la lemmatisation.

Au contraire, pour utiliser SBERT on va préférer garder le texte le plus brut possible avant de le vectoriser.

Cela vient de la différence de structure des 2 modèles : doc2vec est rapide, basé sur une fenêtre glissante, et efficace pour des tâches simples ; SBERT, plus lourd, encode le sens global d'un texte via des Transformers, avec une bien meilleure précision sémantique.

2.9 Finetuning de SBERT

Comme énoncé plus tôt, la question se pose de la nécessité d'un fine-tuning du modèle d'embedding utilisé. En effet, étant donné le **champ des discussions très resserré autour de la politique monétaire**, l'embedding va se concentrer seulement dans une seule région de l'espace. L'étape de fine-tuning pourrait permettre alors d'**améliorer la précision de SBERT sur des textes économiques**.

Nous utilisons pour cela le *FinSTS Golden Dataset*, disponible librement sur la plateforme Hugging Face [1]. Ce jeu de données est conçu pour des tâches de similarité sémantique sur des textes financiers.

Il contient 4000 paires de phrases, chacune annotée par deux scores de similarité entre 0 et 5 : un attribué par GPT-4 Turbo, l'autre par un annotateur humain. Dans notre cas, nous nous basons sur le score humain. En répartissant les données en 3000 paires pour l'entraînement et 1000 pour la validation, nous observons rapidement un phénomène d'overfitting avec le modèle `all-MiniLM-L6-v2`.

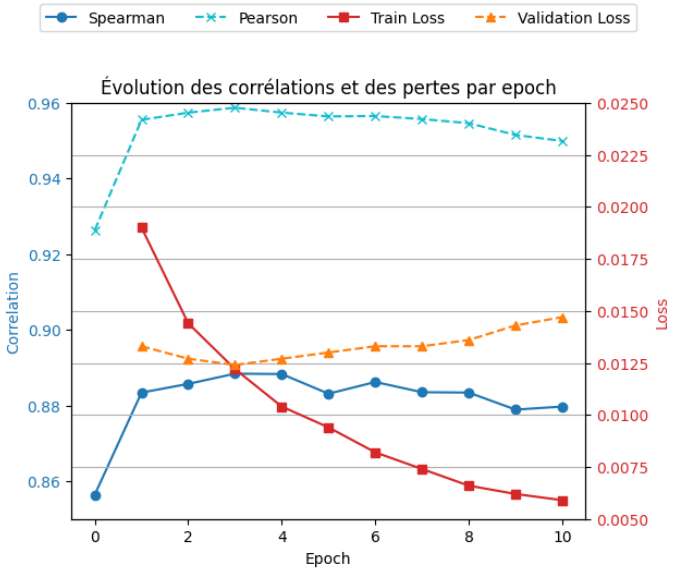

FIGURE 1 – Finetuning de all-MiniLM-L6-v2 sur 10 epochs

1. `https://huggingface.co/datasets/syang687/FinSTS`

Les corrélations de Spearman et de Pearson mesurent la qualité de la prédiction de similarité du modèle vis-à-vis des scores humains. La corrélation de Pearson évalue la relation linéaire entre les prédictions et les annotations, tandis que celle de Spearman mesure la cohérence dans l'ordre des similarités, indépendamment de l'échelle.

On observe sur la Figure 1 que si la perte d'entraînement diminue continuellement, les corrélations sur les données de validation plafonnent rapidement et en particulier la validation loss commence à augmenter, ce qui suggère un **surapprentissage au-delà de 3 epochs**.

La raison vient principalement de la **taille du dataset**, notre modèle a plus de 7 millions de paramètres et il a déjà été entrainé rigoureusement. Le finetuning semble augmenter les corrélations de Spearman et de Pearson de 0.03 pour chacune, ce qui apparait comme la limite avec seulement 3000 couples.

Vérifions si ce finetuning a changé les mesures d'influence :

Top Influence Speaker	FS	BS	Infl.	Top FS Speaker	FS	BS	Infl.	Top BS Speaker	FS	BS	Infl.
MS. RASKIN	0.3704	0.3545	1.0449	MS. PHILLIPS	0.4395	0.4404	0.9978	MS. PHILLIPS	0.4395	0.4404	0.9978
MR. POWELL	0.3969	0.3803	1.0436	MR. GEITHNER	0.4304	0.4342	0.9911	MR. BOSTIC	0.4285	0.4366	0.9814
MR. LOCKHART	0.3754	0.3652	1.0280	MR. BOSTIC	0.4285	0.4366	0.9814	MR. GEITHNER	0.4304	0.4342	0.9911
MR. HELLER	0.3759	0.3666	1.0252	MR. KOHN	0.4270	0.4259	1.0025	MR. SANTOMERO	0.4255	0.4322	0.9845
MR. OLSON	0.3393	0.3311	1.0250	MR. SANTOMERO	0.4255	0.4322	0.9845	MR. KROSZNER	0.4197	0.4265	0.9842
MR. GREENSPAN	0.2559	0.2505	1.0216	MR. KROSZNER	0.4197	0.4265	0.9842	MR. KOHN	0.4270	0.4259	1.0025
MS. BRAINARD	0.4069	0.3989	1.0202	MR. GRAMLEY	0.4150	0.4147	1.0007	MR. SYRON	0.4147	0.4164	0.9958
MR. LAWARE	0.3857	0.3781	1.0200	MR. SYRON	0.4147	0.4164	0.9958	MR. GRAMLEY	0.4150	0.4147	1.0007
MR. DUDLEY	0.3141	0.3081	1.0195	MR. KASHKARI	0.4106	0.4143	0.9911	MR. KASHKARI	0.4106	0.4143	0.9911
MR. LINDSEY	0.3137	0.3080	1.0185	MR. STERN	0.4085	0.4082	1.0008	MR. STERN	0.4085	0.4082	1.0008
MR. BOYKIN	0.3415	0.3359	1.0166	MS. BRAINARD	0.4069	0.3989	1.0202	MR. HOENIG	0.4058	0.4062	0.9990
MR. WINN	0.3466	0.3409	1.0165	MR. HOENIG	0.4058	0.4062	0.9990	MR. MOSKOW	0.3995	0.4017	0.9946

TABLE 5 – Mistral + SBERT finetuné : Top 12 des métriques d'influence, de similarité future (FS), et de similarité passée (BS) depuis 1979, filtré par expérience supérieure à 12 meetings.

Interprétation : Le top 12 reste sensiblement le même, bien que l'ordre ait quelque peu évolué. En revanche, les scores de FS et de BS les plus élevés ont diminué d'environ 0.1, ce qui semble indiquer que **le modèle fine-tuné parvient un peu mieux à différencier les sujets abordés**. Cependant, cette diminution n'a pas entraîné de variation significative dans les classements de FS et de BS. Il y aurait donc un intérêt à fine-tuner le modèle sur un volume de données plus important, afin de déterminer si l'amélioration est réellement significative.

2.10 Etude économétrique

2.10.1 Lien entre influence et expérience

Intéressons-nous à savoir si **l'expérience joue un rôle sur l'influence des membres**. À première vue, il semblerait **logique qu'il y ait une corrélation positive entre les deux** : plus on a d'expérience, plus il est naturel d'avoir un rôle déterminant dans les réunions.

Vérifions visuellement cette relation en traçant l'influence en fonction de l'expérience :

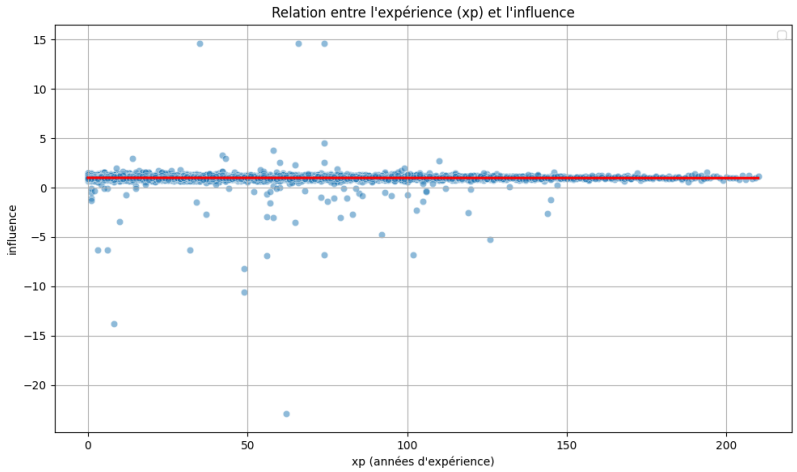

FIGURE 2 – expérience = f(influence)

Outre quelques valeurs aberrantes, il n'apparaît aucune relation évidente entre ces deux grandeurs. Vérifions-le par une régression linéaire :

$$\text{influence}_i = \alpha_0 + \alpha_1 \cdot \text{xp}_i + \alpha_2 \cdot \text{Phd}_i + \alpha_3 \cdot \text{gender}_i + \alpha_4 \cdot \text{bankpres}_i + \varepsilon_i,$$

où :

- **Phd** = 1 s'il a un doctorat, 0 sinon,
- **xp** = nombre de réunions précédemment assistées,
- **gender** = 1 si femme, 0 sinon,
- **bankpres** = 1 si président d'une banque régionale de la Fed ; 0 si gouverneur du Board.

Résultats de la régression linéaire (Mistral + SBERT)

```
OLS Regression Results
==============================================================================
Dep. Variable:            influence   R-squared:                       0.004
Model:                          OLS   Adj. R-squared:                  0.003
Method:               Least Squares   F-statistic:                     6.105
Date:              Fri, 25 Jul 2025   Prob (F-statistic):           6.71e-05
Time:                      13:53:13   Log-Likelihood:                -545.76
No. Observations:              6271   AIC:                             1102.
Df Residuals:                  6266   BIC:                             1135.
Df Model:                         4
Covariance Type:           nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const          0.9968      0.008    123.953      0.000       0.981       1.013
xp            -0.0002   8.67e-05     -2.496      0.013      -0.000   -4.64e-05
```

```
Phd           -0.0161      0.007     -2.302      0.021      -0.030      -0.002
gender         0.0064      0.010      0.627      0.531      -0.014       0.026
bankpres       0.0276      0.007      3.712      0.000       0.013       0.042
==============================================================================
Omnibus:                     8395.249   Durbin-Watson:                   1.807
Prob(Omnibus):                  0.000   Jarque-Bera (JB):          4483322.394
Skew:                          -7.231   Prob(JB):                         0.00
Kurtosis:                     133.189   Cond. No.                         216.
==============================================================================
```

Effectivement, la significativité statistique du coefficient de l'expérience est élevée, au seuil de 5%, mais sa valeur est égale à 0 à 10e-5 près. Ce **résultat peut sembler fortement contradictoire avec l'intuition**, et invite à interroger la pertinence de la méthode utilisée pour mesurer cette influence, ou en tout cas sur la quantitée qui est effectivement mesurée.

2.10.2 Lien entre dissidence et diversité intra-réunion

On va s'intéresser dans cette partie à établir une relation entre la dissidence (**voter non**) et la diversité intra-réunion (**s'exprimer différemment des autres membres lors d'un meeting**). Cela revient à se demander si les membres qui votent non apportent de nouvelles idées ou non.

Afin de quantifier à quel point un individu s'écarte du consensus discursif au sein d'une réunion, nous définissons les mesures suivantes :

- Pour chaque individu i lors d'une réunion donnée, nous calculons ρ_i, le produit scalaire entre son vecteur d'embedding de sa déclaration la plus longue et celui des autres participants à la même réunion.
- Nous calculons ensuite $\overline{\rho}$, la moyenne des ρ_i au sein de cette réunion, qui reflète le niveau moyen de similarité des discours.
- Enfin, nous définissons la **mesure de diversité individuelle** comme :

$$\rho_{\text{div}} = \overline{\rho} - \rho_i$$

  Cette valeur représente **à quel point le discours de l'individu i diffère de celui des autres membres du meeting par rapport à la diversité déjà présente**.

NB : on définit ici une diversité relative à un meeting, i.e on considère qu'un discours est d'autant plus divergent qu'il s'inscrit dans un meeting homogène. On ne considère pas alors qu'une intervention est différente si elle s'inscrit dans un meeting où chacun donne une idée différente.

Pour ce qui est des votes, on observe 3619 votes favorables (`vote_dissent` = 0) contre 271 votes dissidents (`vote_dissent` = 1), soit environ 7% de dissidence. Bien que le déséquilibre soit marqué, cette proportion reste suffisante pour estimer une régression logistique de manière valide.

Nous commençons par estimer une régression logistique simple, où la variable `vote_dissent` est expliquée par l'écart discursif au consensus, `rho_div`, selon le modèle suivant :

$$\text{vote_dissent}_i = \alpha_0 + \alpha_1 \cdot \rho_{\text{div},i} + \varepsilon_i$$

Résultats de la régression simple

Avec Mistral + SBERT

```
Logit Regression Results
Dep. Variable:     vote_dissent         No. Observations:    3890
Model:             Logit                Df Residuals:        3888
Method:            MLE                  Df Model:            1
Date:              Thu, 24 Jul 2025     Pseudo R-squ.:       0.002021
Time:              15:10:15             Log-Likelihood:      -981.30
converged:         True                 LL-Null:             -983.29
Covariance Type:   nonrobust            LLR p-value:         0.04621

                coef    std err    z      P>|z|   [0.025    0.975]
const         -2.5936   0.063   -41.053   0.000   -2.717   -2.470
rho_div       -1.4448   0.763    -1.893   0.058   -2.941    0.051
```

Avec Doc2Vec

```
Logit Regression Results
Dep. Variable:     vote_dissent         No. Observations:    3890
Model:             Logit                Df Residuals:        3888
Method:            MLE                  Df Model:            1
Date:              Thu, 24 Jul 2025     Pseudo R-squ.:       5.587e-06
Time:              15:19:12             Log-Likelihood:      -983.28
converged:         True                 LL-Null:             -983.29
Covariance Type:   nonrobust            LLR p-value:         0.9165

                coef    std err    z      P>|z|   [0.025    0.975]
const         -2.5914   0.063   -41.080   0.000   -2.715   -2.468
rho_div       -0.1764   1.684    -0.105   0.917   -3.477    3.124
```

Interprétation : On observe un effet significatif de ρ_{div} sur la probabilité de dissidence lorsqu'on utilise Mistral + SBERT au seuil de 10%, mais il n'y a aucun effet détecté avec Doc2Vec à tous les seuils possibles. Cela suggère que la qualité de l'encodage sémantique influence les résultats.

Régression avec variables de contrôle

Afin de tester la robustesse du modèle, nous introduisons des variables de contrôle liées : au parcours académique (Phd), à l'expérience (xp), au genre (gender), à la résonnance du discours (influence).

Le modèle devient alors :

$$\text{vote_dissent}_i = \alpha_0 + \alpha_1 \cdot \rho_{\text{div},i} + \alpha_2 \cdot \text{xp}_i + \alpha_3 \cdot \text{Phd}_i + \alpha_4 \cdot \text{gender}_i + \alpha_5 \cdot \text{influence}_i + \varepsilon_i$$

Résultats avec variables de contrôle

Avec Mistral + SBERT (avec variables de contrôle)

```
Logit Regression Results
Dep. Variable:     vote_dissent         No. Observations:    3868
```

```
Model:              Logit                Df Residuals:        3862
Method:             MLE                  Df Model:            5
Date:               Thu, 24 Jul 2025     Pseudo R-squ.:       0.01068
Time:               15:13:36             Log-Likelihood:      -971.21
converged:          True                 LL-Null:             -981.70
Covariance Type:    nonrobust            LLR p-value:         0.0008217

                 coef    std err    z      P>|z|   [0.025    0.975]
const         -3.1462   0.175   -17.992   0.000   -3.489   -2.803
rho_div       -1.5194   0.757    -2.008   0.045   -3.002   -0.037
xp             0.0042   0.002     2.640   0.008    0.001    0.007
Phd            0.3501   0.138     2.533   0.011    0.079    0.621
gender         0.1281   0.177     0.722   0.470   -0.219    0.476
influence      0.1084   0.109     0.998   0.318   -0.104    0.321
```

Avec Doc2Vec

```
Logit Regression Results
Dep. Variable:      vote_dissent         No. Observations:    3868
Model:              Logit                Df Residuals:        3862
Method:             MLE                  Df Model:            5
Date:               Thu, 24 Jul 2025     Pseudo R-squ.:       0.007754
Time:               15:19:12             Log-Likelihood:      -974.08
converged:          True                 LL-Null:             -981.70
Covariance Type:    nonrobust            LLR p-value:         0.009450

                 coef    std err    z      P>|z|   [0.025    0.975]
const         -2.9240   0.289   -10.126   0.000   -3.490   -2.358
rho_div       -0.4619   1.698    -0.272   0.786   -3.789    2.866
xp             0.0040   0.002     2.500   0.012    0.001    0.007
Phd            0.3432   0.138     2.481   0.013    0.072    0.614
gender         0.1507   0.177     0.851   0.395   -0.196    0.498
influence     -0.0969   0.251    -0.387   0.699   -0.588    0.394
```

Interprétation : Le lien entre diversité et dissidence devient significatif à 5% lorsqu'on utilise Mistral + SBERT après introduction des variables de contrôle. Ce n'est pas le cas avec Doc2Vec, pour lequel l'effet de ρ_{div} reste nul et non significatif à tous les seuils possibles.

Conclusion : Bien qu'avec l'embedding fourni par `doc2vec` la relation entre ρ_{div} et la dissidence apparait comme statistiquement non significative, cette relation devient significative lorsqu'on utilise Mistral pour résumer la déclaration puis SBERT pour la vectoriser.

Contre-intuitivement, cette influence est négative : lorsque ρ_{div}, c'est-à-dire la singularité du discours, augmente, la probabilité de dissidence diminue (le vote se rapproche donc d'un vote favorable).

On aurait pu s'attendre à l'effet inverse. Pourtant, SBERT révèle que les individus qui votent contre ont tendance à tenir un discours dont les thèmes sont plus proches de ceux du meeting. Une explication possible est que ces individus reprennent les arguments du consensus pour les critiquer, avant d'exprimer leur désaccord par un vote dissident. Ainsi, ceux qui votent non ont plus tendance à pointer la raison de leur désaccord qu'apporter une nouvelle piste de solution.

2.11 Conclusion étude de la Fed

Cette étude des discours de la Fed a constitué pour moi une première expérience avec les méthodes de NLP. Plusieurs problèmes ont été mis en avant : **une limite d'entrée pour la plupart des modèles de 512 tokens, un temps de calcul qui peut devenir très long étant donné la taille des données, un système de boite noire qui donne des résultats difficiles à interpréter rigoureusement**.

Pour reprendre les résultats, on a obtenu 2 classements des personnalités les plus influentes, un avec Mistral et SBERT, l'autre avec Doc2vec. Bien que l'un ait pris plus de 50h et l'autre 5 mins à se calculer, aucun ne se dégage clairement sur son top et les 2 semblent fournir des résultats pertinents. Quelques analyses économétriques ont poursuivi l'étude, mais dans les 2 cas les résultats semblent contre-intuitifs, avec une influence qui ne serait pas dépendante de l'expérience, ainsi qu'une propension à voter non qui apparait davantage chez ceux qui tendent à s'exprimer de la même manière que le groupe.

Un point clé qui doit être pris en compte est lorsqu'on travaille sur des quantités de données relativement faibles, par exemple un seul meeting, les résultats sont vérifiables à la main, c'est à dire en reprenant intervention par intervention pour vérifier si les calculs sont cohérents. En revanche pour des études comme celle qu'on vient de réaliser, **le principal point négatif des embeddings est qu'on passe dans un espace latent que l'on ne maitrise plus vraiment**.

On peut réaliser des **nouvelles opérations impossibles à temps humain**, comme parcourir toutes les transcripts de la FOCM, et effectuer certaines mesures dessus, or le processus de mesure est encore **très boite noire pour être interprété**. Pour les résultats obtenus en table 3 et 4, plusieurs questions se posent comme comment vérifier que l'un est nettemement meilleur que l'autre, ou bien que des résultats qui apparaissent comme pertinents ne sont pas dûs à un coup de chance ou bien liés à notre propre subjectivité.

C'est pourquoi les Transformers apportent des pistes de solutions très intéréssantes car jusque là inenvisageable par d'autres méthodes, mais un travail reste à faire sur l'interprétation et le sens qu'on donne à ces résultats. La suite du stage ne va pas concerner les Transformers mais d'autres méthodes de NLP.

3 Etude des discours du Congrès des Etats-Unis

3.1 Sujet de l'étude

Nous allons maintenant nous intéresser à un nouveau sujet, l'étude des comptes rendus officiels quotidiens du Congressional Record. Cela revient à étudier les **discours et débats de la Chambre et du Sénat**.

Le Congrès au Etats Unis est l'organe qui fait les lois au niveau national et approuve le budget fédéral. On récupère sur le site de Stanford les discussions entre le Congrès 97 et 114, soit entre 1981 et 2017, ce qui représente **plus de 4go de données textuelles**.

L'objectif va être d'étudier **comment les Républicains et les Démocrates parlent de politique monétaire et de la Fed**, i.e déterminer si ils supportent ou non leurs décisions.

3.2 Interprétation par contexte : 2 approches différentes

Etant donné la quantité phénoménale de données textuelles, l'utilisation de méthodes NLP et en particulier le word embedding va être justifié.

Pour interpréter au mieux les discussions des deux partis, 2 méthodes semblent intéréssantes.
La première va utiliser le contexte d'un sujet relatif à un mot (par exemple *immigration*) pour en déterminer un embedding spécifique qui permettra d'avoir le sens précis qui est utilisé dans la phrase, ce sera la méthode **A La Carte** (ALC).
La seconde va utiliser un réseau de neurones pour déterminer si le mot s'utilise davantage dans un contexte propre à un parti plus qu'à l'autre, ce sera la méthode **Neural Network** (NN).

NB IMPORTANT : Ici **aucune des deux méthodes n'utilise de transformers pour l'embedding** (ni ALC ni NN), comme par exemple BERT (2018) ou SBERT (2019).
On s'intéresse dans notre étude à l'avis des membres du Congrès sur une idée en particulier, par exemple l'immigration ou la Fed. L'enjeu n'est donc pas de comparer les discussions entre elles comme ça a pu être le cas avec les transcrips de la FOCM, mais de comparer les propos tenus par les membres du Congrès à des sujets qui vont restés fixes dans le temps.
On a alors besoin d'une représentation vectorielle fixe, qui est fournie par des méthodes d'embeddings telles que glove (2014) pour ALC ou word2vec (2013) pour NN.
En effet dans ces méthodes, à la différence de BERT qui donne un embedding différent pour chaque contexte, la faiblesse de word2vec de fournir **un seul embedding pour chaque mot peu importe le contexte** en fait aussi son intérêt car on peut alors **comparer ces embeddings fixes à ceux qu'on calcule** avec nos méthodes.

3.3 Première méthode : la méthode A La Carte

3.3.1 Principe

On va utiliser la méthode développée dans l'article *Embedding Regression : Models for Context-Specific Description and Inference* publié en 2022.

Cette méthode fait face au sujet suivant : **on souhaiterait savoir à quoi font référence les Républicains et les Démocrates lorsqu'ils parlent par exemple d'immigration**, i.e quel sens ils attachent à ce mot.

Le problème classique lorsqu'on utilise des méthodes d'embeddings statiques comme Glove, qui attribue à chaque mot un embedding pré-définie, est qu'**on perd toute l'information contenue dans la phrase sur le contexte de l'utilisation du mot**, par exemple si c'est dans une tournure culturelle, économique, etc.

Une solution évidente à ce problème tient dans la formule classique : **You shall know a word by the company it keeps**, J.R. Firth (1957). On pourrait alors simplement prendre une fenetre autour du mot, disons 3 mots avant et 3 mots après et de faire la moyenne de tous ces vecteurs. Dans ce cas, on obtient bien un vecteur propre au mot cible qui est différent en fonction des contextes. La limitation de cette méthode apparait très vite lorsqu'on regarde qui sont les mots qui ressemblent le plus à ces vecteurs. On se rend compte qu'en faisant ce processus, on va avoir des vecteurs pour chacun des mots cibles qui sont totalement noyés dans la masse, i.e nos vecteurs vont très vite ressembler à des 'the', 'of, etc (qu'on nomme stopwords), des vecteurs sans aucune signification ni intérêt.

L'explication est simplement que lorsqu'on fait la moyenne brute autour du mot, on ne pondère pas l'importance des mots dans le contexte. D'ailleurs retirer les stop words ne fonctionne pas comme une solution miracle puisque la liste de mots qui s'utilisent partout et qui n'apportent pas grand chose n'a pas vraiment de limite, i.e en les retirant on va quand même avoir nos vecteurs qui vont ressembler fortement à des mots comme 'way', 'time', 'come', 'month', 'likely', etc.

C'est pourquoi on va avoir besoin de notre méthode ALC, afin d'**obtenir pour un mot cible, un embedding spécifique au contexte, en pondérant les différents mots de notre contexte pour leur attribuer une importance légitime**.

Toute la méthode repose sur le principe suivant : on part d'un espace d'embeddings statiques pré-entraînés, par exemple Glove, où chaque mot du vocabulaire possède un vecteur fixe. Pour un mot cible apparaissant dans une phrase, on définit un contexte (par ex. une fenêtre de trois mots avant et trois mots après) et on retire le mot cible pour ne conserver que les mots périphériques, dont on connaît également les vecteurs Glove.

On construit ensuite v_{contexte} en prenant l'embedding moyen des mots du contexte (le mot cible étant retiré). Puis, sur un grand corpus (ex. Wikipédia), on apprend une matrice de transformation A qui minimise l'erreur entre le vecteur moyen du contexte transformé $\left(A \cdot v_{\text{contexte}}\right)$ et le vecteur fixe du mot cible. L'intérêt est que tous les vecteurs sont connus (issus de Glove), l'estimation de A revient donc à résoudre :

$$\hat{A} \;=\; \arg\min_{A} \sum_{w=1}^{W} \alpha(n_w) \left\|\mathbf{v}_w - A\,\mathbf{u}_w\right\|_2^2,$$

où :

- W est le nombre de mots (ou d'entrées) utilisés pour l'estimation ;
- $\mathbf{v}_w \in R^{300}$ est l'embedding *fixe* (Glove) du mot w ;
- $\mathbf{u}_w \in R^{300}$ est le vecteur de *contexte moyen* associé à w (moyenne des embeddings des mots autour de w, sans w lui-même) ;
- $A \in R^{300\times 300}$ est la matrice de transformation recherchée ;
- n_w est la fréquence d'observation du mot w dans le corpus d'estimation ;
- $\alpha(\cdot)$ est une pondération croissante (p. ex. $\alpha(n_w) = \log n_w$) qui reflète la plus grande fiabilité des mots fréquents.

Au final, le rôle de cette matrice est de **pondérer intelligemment l'information des mots du contexte**, en réduisant l'influence des termes très fréquents ou peu porteurs de sens, afin de produire un embedding contextuel précis tout en restant dans le même espace vectoriel fixe.

Une fois que A est estimée, on l'utilise de la même manière : on prend un contexte autour du mot cible (en retirant ce dernier), puis on calcule $\hat{A} \cdot v_{\text{contexte}}$, un vecteur *spécifique* au mot cible dans ce contexte. On obtient ainsi ce que l'on souhaite : **un embedding différent pour chaque occurrence du mot cible, reflétant son sens particulier dans ce contexte**.

3.3.2 Implémentation

Le papier propose un code R qui est prêt à être utilisé avec la matrice A déjà implémentée, cependant la suite de l'étude étant plus simple à poursuivre sur Python j'ai recodé l'ensemble des fonctions, disponibles sur mon GitHub.

Pour ce qui est du choix des paramètres, il est important de tester empiriquement les combinaisons qui donnent les résultats les plus satisfaisants concernant : le choix de la matrice A, laisser ou non les stopwords, la taille de la fenetre autour du mot cible.

Pour ce qui est de la matrice A, celle fournie dans le package R n'est pas entrainée dans le même espace vectoriel fixée que celui de Glove 6B 300d, il faut donc en trouver une adaptée, je l'ai recalculé.
Pour ce qui est des stopwords, le choix apporte peu de différence en réalité mais la règle est la suivante : si la matrice A a été entrainé en gardant les stopwords alors il faut les garder, par la suite je les ai exclu.
Pour ce qui est de la taille de la fenetre, on conseille généralement entre 6 et 12, et c'est une fenetre de 5 avant 5 après qui m'a donné les résultats les plus probants.

3.3.3 Résultats - Plus Proches Voisins

Rappellons que notre objectif était de **savoir le sens qu'attachaient les Démocrates et les Républicains aux mots qu'ils utilisaient**, en particulier lorsqu'ils parlent d'immigration, de la Fed ou de politique monétaire.

On a pu alors calculer avec la méthode ALC un embedding pour chacune des occurences d'un mot cible au cours des discours, avec des métadonnées pour savoir quel parti les utilise.

La méthode développée dans le même article pour attribuer un sens à ces embeddings est de prendre chacun des partis séparément, de prendre la moyenne des embeddings qui ont été calculés par la méthode ALC et de regarder les Plus Proches Voisins (PPV) par similarité cosinus de cette moyenne. Pour être plus clair, **on obtient un vecteur pour chaque parti qui représente l'embedding moyen du mot cible et on regarde parmi tous les mots référencés dans Glove ceux qui minimisent l'angle entre les 2 vecteurs**.

Ainsi, on obtient pour chaque parti les mots qui sont en général utilisés dans le même contexte que celui du mot cible. On obtient alors les tableaux suivants :

On constate alors très vite les limites de la méthode de l'article : bien que pour un mot comme immigration (70000 occurrences) où son utilisation varie fortement en fonction du contexte on arrive à avoir un classement contrasté par parti, cependant des mots comme federal reserve (20000 occurrences) et monetary

Immigration		Federal Reserve		Monetary Policy	
R	**D**	**R**	**D**	**R**	**D**
immigration 0.5655	legislation 0.5957	reserve 0.6880	reserve 0.6860	monetary 0.7504	monetary 0.7464
legislation 0.5472	immigration 0.5532	greenspan 0.6204	greenspan 0.6141	policy 0.6118	policy 0.6144
enact 0.5114	enact 0.5433	bernanke 0.6013	bernanke 0.5907	expansionary 0.5768	expansionary 0.5725
law 0.4952	reform 0.4745	federal 0.5788	fed 0.5815	macroeconomic 0.5387	macroeconomic 0.5258
undocumente 0.4788	amendment 0.4661	fed 0.5786	federal 0.5740	stimulative 0.5052	policymaker 0.5130
enforcement 0.4591	overhaul 0.4660	policymakers 0.5324	policymakers 0.5390	tighten 0.4991	tighten 0.5020
naturalization 0.4542	law 0.4575	fomc 0.4862	fomc 0.4962	accommodative 0.4947	stimulative 0.5014
toughening 0.4532	enactment 0.4531	fdic 0.4660	fdic 0.4634	budgetary 0.4872	fomc 0.4996
toughen 0.4434	provision 0.4492	volcker 0.4426	volcker 0.4452	fomc 0.4847	accommodative 0.4915
regulation 0.4306	mandate 0.4448	blinder 0.4381	blinder 0.4414	prudent 0.4779	prudent 0.4724

TABLE 6 – Similarité cosinus des PPV Glove en fonction du parti Républicain ou Démocrate

policy (5000 occurrences) **ne s'emploient pas dans des contextes suffisamment discriminateurs**.

En regardant de plus près immigration, on a bien un contexte juridique et législatif commun, mais pour les Républicains tourné vers le contrôle et la sécurité (*enforcement, toughen, toughening, undocumente*) tandis que les Démocrates mettent l'accent sur le changement et l'adaptation des lois (*reform, overhaul, amendment*).

Une piste de réflexion pourrait être que la moyenne brute est une opération trop forte pour des concepts comme federal reserve et monetary policy. En effet si on se représente l'espace des embeddings en 2D, imaginons que les républicains utilisent federal reserve dans un contexte qui le place en (-1,1) puis dans un autre en (1,-1), en moyennant on se retrouve en (0,0), or le résultat est exactement le même si les démocrates avaient utilisé federal reserve en (-1,-1) puis en (1,1), même finalité pour 2 idées opposées.

Il est légitime de s'intéresser alors aux PPV pour chaque occurrence du mot cible. On va donc incrémenter un compteur de +1 au premier PPV de chaque occurrence du mot cible, on obtient le tableau suivant :

Immigration		Federal Reserve		Monetary Policy	
R	**D**	**R**	**D**	**R**	**D**
illegal 1423	naturalization 1168	reserve 1621	reserve 2895	monetary 822	monetary 1009
naturalization 1022	reform 1003	greenspan 613	greenspan 742	subcommittee 120	subcommittee 183
bill 792	bill 968	federal 338	federal 623	policy 108	policy 145
subcommittee 685	subcommittee 783	treasury 214	rate 316	rate 32	rate 54
reform 638	illegal 695	monetary 198	treasury 310	inflation 27	reserve 48
law 638	comprehensive 510	bernanke 173	monetary 304	reserve 24	feed 35
enforcement 628	amendment 487	volcker 161	volcker 284	feed 24	fiscal 30
enforce 602	legislation 477	rate 144	bernanke 262	semiannual 19	economic 28
amendment 523	bipartisan 468	bank 87	bank 166	fiscal 15	inflation 27
legislation 407	enforcement 432	chairman 69	chairman 149	oversight 13	semiannual 24

TABLE 7 – Compteur d'apparition du premier PPV en fonction du parti Républicain ou Démocrate

Etant donné le nombre d'occurrences des mots cibles qui sont drastiquement différents : 60k pour Immigration, 20k pour Federal Reserve et 5k pour Monetary Policy, la table 7 confirme que la méthode de l'article n'est pas adaptée pour des concepts tels que les 2 derniers mots cibles.

Cependant, étant donné qu'on a déjà calculé la moyenne des embeddings du mot cible par parti : μ_R et μ_D, on va alors creuser une nouvelle piste qui n'apparait pas dans l'article en définissant **un axe directionnel** qui capture la différence d'usage entre les deux partis. Plus précisément, on considère les deux moyennes déjà calculées, μ_R et μ_D, comme deux points dans l'espace des embeddings. On construit alors le vecteur

$$d \;=\; \mu_R - \mu_D,$$

que l'on **normalise** pour ne garder que la direction (et non la taille) :

$$\hat{d} \;=\; \frac{d}{\|d\|}.$$

Cet axe $\hat{d}$ "pointe" de μ_D vers μ_R et matérialise la *différence sémantique* entre les usages du mot cible.

Pour tout mot référencé dans Glove w et muni de son vecteur v_w, normalisé, on calcule sa *projection* sur cet axe :

$$\text{score}(w) \;=\; v_w \cdot \hat{d} \;=\; \cos\!\big(v_w, \hat{d}\big).$$

L'interprétation est directe : si score$(w) > 0$, w est *orienté vers* μ_R (pro-R) ; si score$(w) < 0$, w est *orienté vers* μ_D (pro-D) ; et si score$(w) \approx 0$, w est *neutre* vis-à-vis de cet axe (sa variation n'explique pas la différence R/D).

Cette approche ne cherche plus des voisins *absolus* autour de μ_R ou μ_D (ce que fait la similarité cosinus classique), mais des mots qui **maximisent la séparation entre les deux camps le long de l'axe qui les relie**. Deux avantages en découlent : (i) même si $\mu_R \approx \mu_D$ en distance, l'axe $\hat{d}$ reste défini et l'on peut ordonner les mots selon leur *orientation relative* (le signe et l'amplitude de la projection) ; (ii) on évite l'*effet d'annulation* de la moyenne brute (des contextes opposés peuvent se neutraliser dans la moyenne), car le critère est *relationnel* : il mesure de quel côté de la frontière R/D tombe chaque mot et à quel degré.

On obtient finalement les résultats suivants :

Immigration		**Federal Reserve**		**Monetary Policy**	
Pro-R	**Pro-D**	**Pro-R**	**Pro-D**	**Pro-R**	**Pro-D**
illegal 0.5013	bipartisan -0.4382	billions 0.3061	board -0.5678	ills 0.2788	committee -0.3416
illegally 0.4173	blueprint -0.3947	infrastructure 0.2691	commissioners -0.3566	predictability 0.2754	senate -0.3076
prohibited 0.3992	balanced -0.3809	money 0.2559	regents -0.3551	stability 0.2580	board -0.2982
unlawful 0.3784	overhaul -0.3698	paulson 0.2402	directors -0.3363	restoring 0.2545	subcommittees -0.2965
unauthorized 0.3705	reconciliation -0.3696	trillions 0.2401	unanimously -0.3264	capitalism 0.2516	hearings -0.2645
illicit 0.3597	reform -0.3692	costing 0.2393	trustees -0.3250	stable 0.2499	council -0.2556
smuggling 0.3571	comprehensive -0.3598	reconstruction 0.2388	excutive -0.2801	correcting 0.2450	unanimously -0.2473
unlicensed 0.3546	senate -0.3482	financial 0.2383	captains -0.2637	decent 0.2423	appropriations -0.2457
smugglers 0.3295	compromise -0.3295	guaranteeing 0.2360	chairperson -0.2485	stabilizing 0.2394	vacancies -0.2450
profiting 0.3206	stalled -0.3072	taxpayer 0.2281	bulletin -0.2480	longterm 0.2336	appointees -0.2411

TABLE 8 – Projection directionnelle sur l'axe $\hat{d}$: mots les plus alignés pro-R et pro-D.

Cette poursuite de l'étude permet de faire les commentaires suivants :

- pour *immigration*, on observe un contexte juridique et législatif commun, mais le lexique **pro-R** est davantage tourné vers le contrôle et la sécurité (*illegal, unlawul, unauthorized, smuggling, prohibited*), ce qui

renvoie à un cadrage centré sur l'application stricte des lois et la lutte contre les activités illégales. Le **pro-D**, lui, met l'accent sur la réforme et la négociation politique (*bipartisan, overhaul, reconciliation, reform, comprehensive*), reflétant une vision orientée vers le changement des lois et la recherche de compromis.

- pour *federal reserve*, le lexique **pro-R** se concentre sur les aspects financiers et budgétaires concrets (*billions, trillions, taxpayer, money, financial*), avec aussi des références à la reconstruction et aux garanties (*reconstruction, guaranteeing*), ce qui traduit un discours orienté sur les coûts, les ressources et la gestion monétaire. Du côté **pro-D**, on retrouve surtout des termes institutionnels (*board, commissioners, trustees, chairperson*), reflétant un cadrage plus organisationnel et administratif du sujet.

- pour *monetary policy*, le vocabulaire **pro-R** met en avant la stabilité et le rétablissement économique (*stability, restoring, stabilizing, predictability*), ainsi que des notions correctives et structurelles (*correcting, capitalism, longterm*). À l'inverse, le **pro-D** est dominé par un lexique institutionnel et procédural (*committee, senate, subcommittees, council, appropriations*), montrant un ancrage plus fort dans la gouvernance.

3.3.4 Résultats - Régression linéaire

Un dernier point de l'article reste à être étudié et concerne le titre même *Embedding Regression*. Cette dernière partie s'attache à répondre à la question suivante : "**Peut-on quantifier par un test statistique si le sens attribué à un mot est le même pour deux partis différents ?**".

Après avoir construit, pour chaque occurrence d'un mot-cible, un vecteur d'embedding spécifique à son contexte, nous souhaitons quantifier dans quelle mesure l'usage de ce mot diffère entre les partis politiques. L'idée centrale est d'**examiner si, en moyenne, l'embedding du mot prend des valeurs systématiquement différentes selon que le locuteur est Républicain ou Démocrate**.

Pour cela, nous adoptons la méthodologie de l'article qui consiste à modéliser l'ensemble du vecteur d'embedding comme fonction linéaire d'une indicatrice d'appartenance politique. Formellement, pour un mot cible donné, on écrit :

$$Y_i = \alpha + \beta \cdot \mathbb{1}(\text{Républicain}_i) + \varepsilon_i,$$

où :
- Y_i est le vecteur d'embedding (de dimension 300) associé à l'occurrence i du mot cible ;
- $\mathbb{1}(\text{Républicain}_i)$ est une indicatrice valant 1 si le locuteur est Républicain, 0 s'il est Démocrate ;
- α est le vecteur moyen des embeddings pour le groupe de référence (ici, les Démocrates) ;
- β vecteur de taille 300 représentant le déplacement moyen de l'embedding lorsque l'on de D à R ;
- ε_i est un terme d'erreur.

NB : on fait ici une seule regression par MCO multivariés avec Y la variable expliquée sous la forme d'un vecteur de taille 300, ce qui revient mathématiquement à faire 300 OLS classiques, i.e une sur chacune des coordonnées de Y.

Le **vecteur** β ainsi obtenu capture **la direction et l'amplitude du décalage sémantique moyen entre Républicains et Démocrates pour le mot étudié**. Afin de disposer d'une mesure synthétique de l'ampleur de ce décalage, nous considérons la **norme euclidienne** de β : $T_{\textbf{mot}} = \|\beta\|_2$ qui correspond à la **distance, dans l'espace des embeddings, entre le centre de gravité du mot chez les Démocrates** (α) **et celui chez**

les Républicains ($\alpha + \beta$).

Après régression, on obtient les résultats suivants :

$$T_{\text{immigration}} = 0.099 \quad ; \quad T_{\text{federal reserve}} = 0.056 \quad ; \quad T_{\text{monetary policy}} = 0.065$$

Ces résultats confirment bien ceux de la table 6 qu'on avait obtenu en prenant les PPV par similarité cosinus où immigration apparaissait plus polarisée que monetary policy et lui même que federal reserve.

NB : **La valeur de la norme de β apporte à elle seule peu d'information, il est important de rappeler que l'espace des embeddings n'a de sens que pour comparer des valeurs entre elles**, donc comparer des normes de β entre elles par exemple.

L'étape suivante classique lorsqu'on fait une régression est de déterminer si les résultats qu'on obtient – ici, la distance entre le centre de gravité des deux partis – sont simplement dus au hasard ou bien si cette distance est statistiquement significative. Cela revient à interroger les p-values issues des tests statistiques. Or, ces p-values reposent sur des hypothèses fortes qui ne semblent pas tenir ici (voir annexe sur hypothèses régression linéaire) (voir annexes : hypothèses régression linéaire), en raison notamment de :

— Y est vectoriel donc **il ne s'agit pas d'un F-test univarié classique** ;
— corrélations entre les observations (occurrences provenant du même orateur ou du même discours) donc **corrélation des erreurs ce qui fausse les p-values** ;
— corrélations fortes entre les différentes dimensions de l'embedding donc **on ne peut pas utiliser une loi théorique standard pour la statistique de test**.

Test par permutation. Pour résoudre ce problème d'interprétabilité de p-values et évaluer la significativité de la distance $T_{\text{mot}} = \|\beta\|_2$, nous adoptons un *test par permutation*. Sous l'hypothèse nulle H_0 : *l'appartenance à un parti n'affecte pas l'embedding du mot*, les étiquettes politiques (R/D) sont *interchangeables*.

Procédure.

1. **Statistique observée :** calculer $T_{\text{mot}} = \|\hat{\beta}\|_2$ sur les données réelles (comme ci-dessus).
2. **Distribution nulle par permutation :** pour $b = 1, \ldots, B$ (avec B grand, e.g. $B = 2000$),
   (a) permuter les étiquettes R/D ;
   (b) refiter la régression (ou, de façon équivalente, calculer $\hat{\beta}^{(b)} = \overline{Y}_R^{(b)} - \overline{Y}_D^{(b)}$) ;
   (c) calculer $T^{(b)} = \left\|\hat{\beta}^{(b)}\right\|_2$.
3. **p-value empirique :**

$$p \;=\; \frac{1 + \sum_{b=1}^{B} \mathbf{1}\left\{ T^{(b)} \geq T_{\text{mot}} \right\}}{B+1}.$$

NB : Ce test ne requiert pas de supposer une loi théorique pour T : la corrélation entre dimensions de l'embedding et entre observations est *respectée* par construction.

En appliquant cette procédure séparément à chacun des trois mots-cibles avec B=2000, nous obtenons les p-values suivantes :

$$p_{\text{immigration}} = 0.0005 \quad ; \quad p_{\text{federal reserve}} = 0.0005 \quad ; \quad p_{\text{monetary policy}} = 0.0005$$

Ici, les trois p-values sont égales à 5×10^{-4} car, avec la simulation de type Monte-Carlo utilisée, la plus petite valeur observable est bornée par $\frac{1}{B+1} = 5 \times 10^{-4}$ (avec $B = 2000$ permutations). On peut donc bien conclure à une **utilisation significativement différente** des mots *immigration*, *Federal Reserve* et *Monetary Policy* selon le parti ce qui semblait déjà le cas au vu des PPV.

3.4 Deuxième méthode : Neural Network

3.4.1 Principe

La seconde approche s'appuie sur l'article *Word Embeddings for the Analysis of Ideological Placement in Parliamentary Corpora* et **consiste à apprendre, via un réseau de neurones, une représentation vectorielle de chaque discours permettant de distinguer l'orientation politique des locuteurs**.
L'idée est de relier directement l'usage des mots à l'appartenance partisane en optimisant conjointement :

— un vecteur ζ pour chaque couple (parti , année), par exemple (démocrate , 2012), représentant le vocabulaire moyen utilisé à cette date par le parti ;
— un vecteur β pour chaque mot, indiquant comment ce mot est utilisé dans les contextes étudiés.

Le réseau est entraîné sur l'ensemble des débats parlementaires de façon à placer, dans un même espace latent, (i) les vecteurs $\zeta_{p,t}$ associés aux couples *(parti p, année t)* et (ii) les vecteurs β_w associés aux mots w. **L'apprentissage conjoint fait en sorte que deux $\zeta_{p,t}$ proches décrivent des contextes politiques semblables, tandis que deux β proches correspondent à des mots utilisés dans des contextes similaires**.

L'avantage de cette méthode est que tout est déjà implémenté en `Python` : on peut directement récupérer les scripts depuis le `GitHub` de l'auteur[2]. Une fois cet espace appris, on suit l'association d'un mot w avec les discours d'un parti au fil du temps en calculant la similarité cosinus entre le vecteur du mot et le vecteur moyen du parti pour chaque année t : $\mathrm{sim}_{p,t}(w) = \cos\big(\beta_w,\ \zeta_{p,t}\big) = \frac{\beta_w^\top \zeta_{p,t}}{\|\beta_w\|\ \|\zeta_{p,t}\|}$.

3.4.2 Résultats

On obtient ainsi, pour nos mots cibles déjà étudiés, deux séries temporelles (Démocrates / Républicains) que l'on peut tracer sur le même graphique, commençons par immigration :

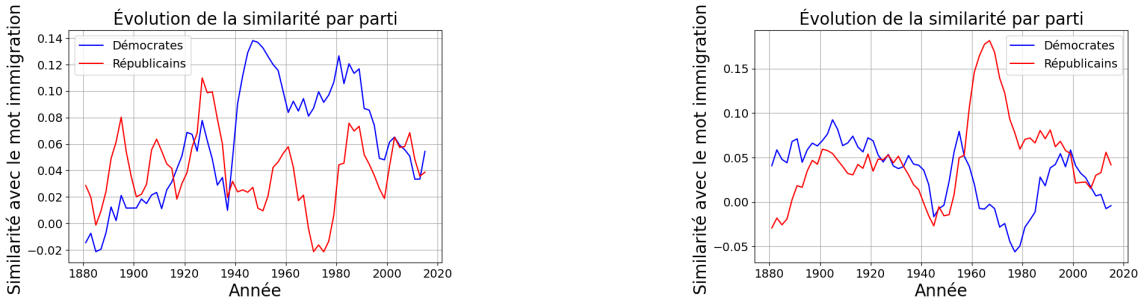

(a) Chambre (*House*)

(b) Sénat

FIGURE 3 – **Similarité immigration – parti dans le temps**.

2. `https://github.com/lrheault/partyembed/tree/master`

On observe jusqu'aux années 1940 des trajectoires assez parallèles entre Démocrates et Républicains, où le mot *immigration* n'est pas encore fortement polarisé. L'après-Seconde Guerre mondiale marque une rupture : dans la Chambre, le terme se rapproche nettement du discours démocrate tandis qu'au Sénat, c'est surtout à partir de l'adoption de l'Immigration and Nationality Act de 1965 que l'on voit une forte divergence en faveur des Républicains.

Continuons avec le mot *fed* :

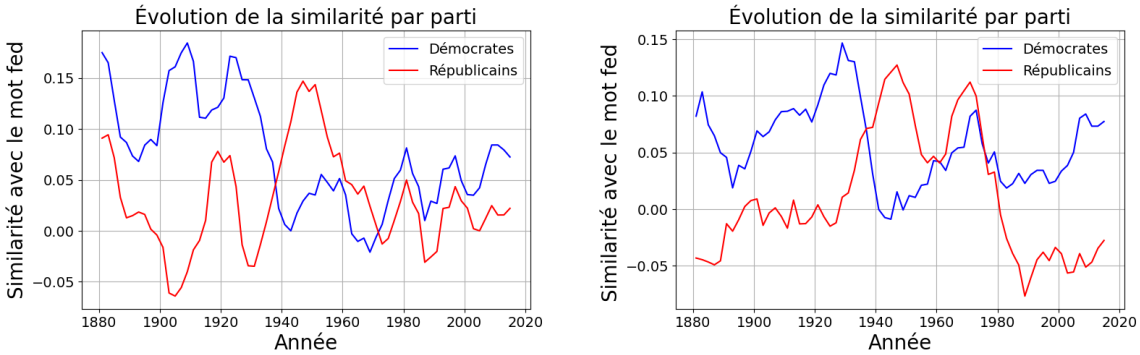

(a) Chambre (*House*)

(b) Sénat

FIGURE 4 – **Similarité fed – parti dans le temps**.

Ici malgré quelques périodes où les partis divergent, notamment en 1930 où la tendance est de signe opposée, les deux partis semblent suivre des tendances communes de manière générale et le sujet autour de **fed** est davantage propre aux Démocrates qu'aux Républicains. Néanmoins, fed est polysémique et correspond aussi au participe passé du verbe nourrir, il est alors pertinent d'interroger ses PPV étant donné qu'on a produit un embedding pour chaque mot :

House	**Senate**
(feds, 0.584), (fed_fed, 0.568), (feeding, 0.510), (monetary_policy, 0.488), (feed, 0.475), (stomachs, 0.443), (eral, 0.441), (eat, 0.440), (volcker, 0.437), (arthur_burns, 0.436)	(federal_reserve, 0.599), (feds, 0.573), (federal_reserve_board, 0.541), (monetary_policy, 0.529), (fed_fed, 0.517), (volcker, 0.474), (feed, 0.467), (ben_bernanke, 0.462), (bernanke, 0.460), (feeding, 0.446)

TABLE 9 – Principaux voisins du mot *fed* dans les embeddings House et Senate (similarité cosinus).

La table 9 nous avertit alors d'un piège important sur l'embedding de mots tels que **fed**, où sans faire attention au contexte on peut bruiter totalement le sens qu'on lui attribue car on va faire la moyenne avec des embeddings de mots qui n'ont rien à voir, comme ici pour la Chambre.

Intéréssons nous alors au Sénat et son utilisation spécifique de **Federal Reserve** :

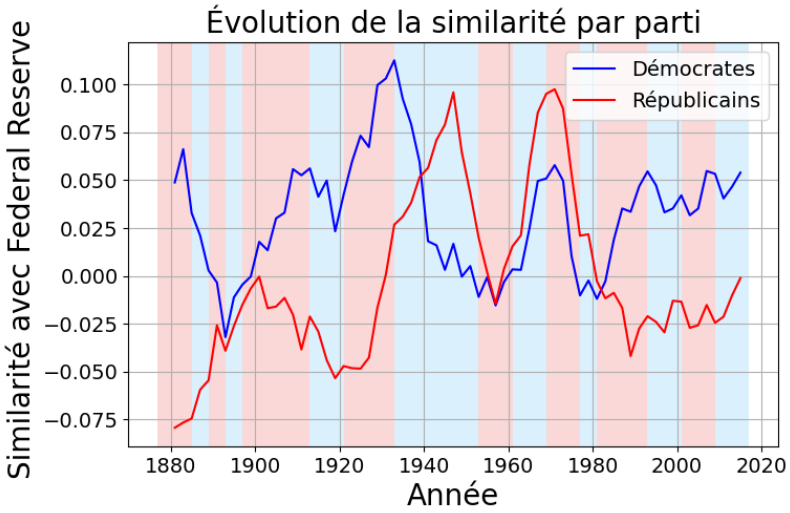

FIGURE 5 – Cas du Sénat

Le graphique montre d'abord une domination démocrate dans l'association au thème de la Fed, suivie d'inversions notables autour des années 1950 et 1970. L'ajout en arrière-plan des alternances présidentielles suggère que l'intérêt pour la Fed tend à croître surtout dans le camp opposé au président en place, puis à décroître lorsque le pouvoir est exercé par le même parti, sans doute parce que la référence à la Fed sert davantage de levier critique.

Puis pour monetary policy, les résultats semblent moins interprétables car les partis semblent suivre des cycles économiques et des alternances politiques :

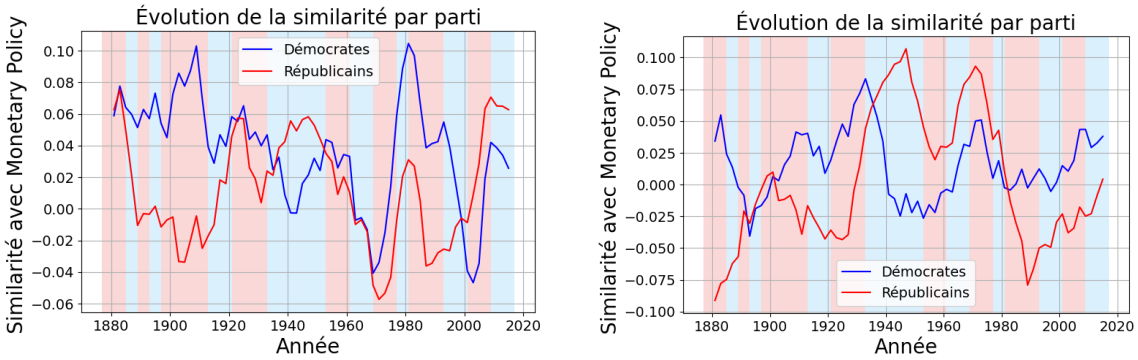

(a) Chambre (*House*)

(b) Sénat

FIGURE 6 – **Similarité Monetary Policy – parti dans le temps**.

3.5 Poursuite de la méthode A La Carte

3.5.1 Evolution de la norme de β

Au vu des résultats précédents difficilement interprétables, **on va revenir à la méthode ALC**, avec une modification considérable. On travaillait jusque là avec le dataset de Stanford qui était récupéré par chaine automatique de traitement OCR, c'est à dire qu'à partir du scan des transcripts des réunions, on récupérait les prises de paroles successives. Or en vérifiant les données, on voit qu'on a régulièrement des fautes, comme des mots ou des phrases coupés, des points partout, etc. La qualité de l'embedding et donc de tout ce qui suit étant directement lié à la qualité des données, **on va passer sur le dataset de Harvard qui étudie les Congrès de 1995 à 2024**. Ce dernier présente une corrélation de Pearson de 0.8 avec celui de Stanford, ce qui nous indique un contenu sensiblement différent.

Avec des données récentes, on souhaiterait s'intéresser à un autre point qui n'avait pas été abordé dans l'article, **concernant l'évolution de la norme de β**.
Rappelons le contexte, on a calculé un embedding spécifique à chaque utilisation d'un mot cible (par exemple *immigration*) avec la méthode ALC puis on a obtenu un vecteur moyen par parti de toutes ces utilisations. Tous les vecteurs étant de même dimension, il est facile de calculer la distance euclidienne entre les 2, on obtient alors cette norme de β qu'on nomme T. Pour chacun des trois mots cibles on recalcule T sur les nouvelles données :

$$T_{\text{immigration}} = 0.11 \quad ; \quad T_{\text{federal reserve}} = 0.066 \quad ; \quad T_{\text{monetary policy}} = 0.079$$

T **correspond donc à la distance entre les centroïdes moyens relatifs aux 2 partis pour le mot cible**. L'interprétation de T n'est pas absolu, on s'intéresse plutôt à l'interprétation relatives entre T de différents mots cibles, ici on déduit que *immigration* est davantage polarisée que *monetary policy*, lui même davantage que *federal reserve*.

Or avec cette méthode, on propose un unique T pour toutes les interventions incluant le mot cible, de 1995 à 2024. **En faisant la moyenne, on perd totalement l'information de l'évolution de T au cours du temps, par exemple si il admet des variations brusques lors de crises**. Traçons donc l'évolution de T, d'abord pour **immigration** :

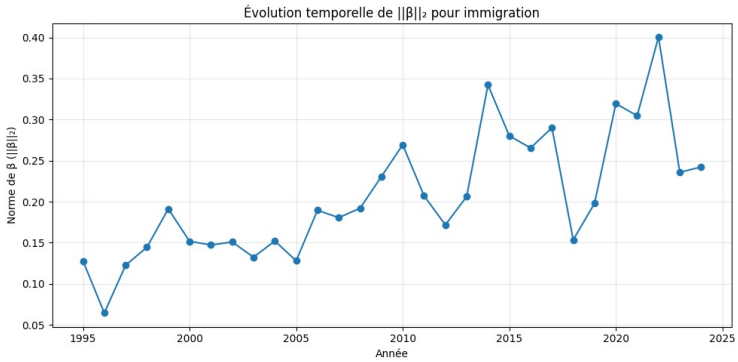

On constate une polarisation croissante sur l'immigration depuis les années 2000. Sous la présidence Trump (2017–2021), elle a presque triplé, l'immigration étant devenue un pilier central de sa campagne. Quant à **federal reserve** et **monetary policy** :

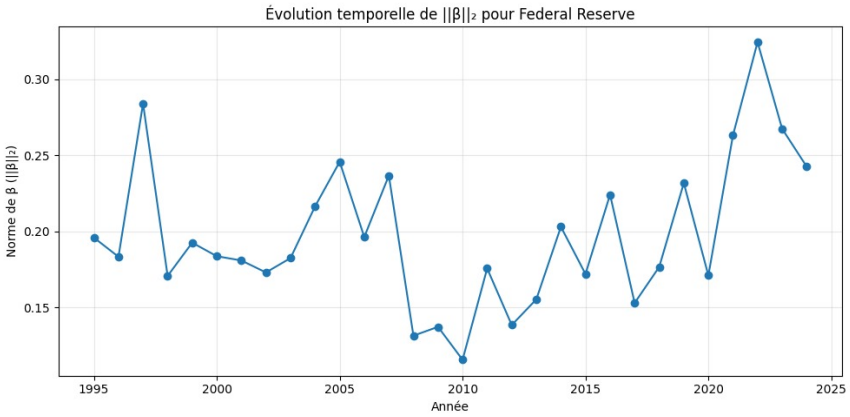

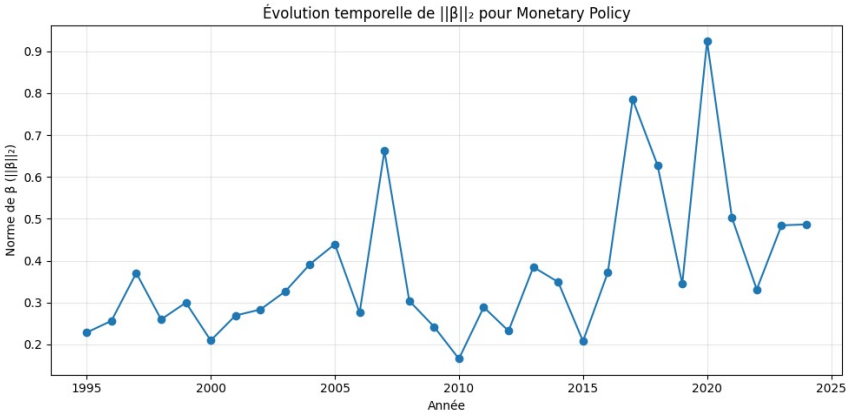

Pour ce qui est de la Fed, on a des divergences sinusoïdales à partir de la crise de 2008, puis un pic pour 2021 où la gestion du Covid par la Fed avec des taux proches de 0 a été perçu comme nécessaire par les démocrates mais critiqué par les républicains.
Le même pic est retrouvé pour la politique monétaire avec des divergences records pendant la période Trump 2017 et Covid 2021.

3.5.2 Corrélation avec indices boursiers

Le graphique met en évidence plusieurs pics marqués (maximums locaux) à certaines années, cela témoigne de phases de polarisation nettement accrue au Congrès autour de la politique monétaire. Examinons alors le lien entre ces épisodes de forte polarisation et l'évolution d'indices boursiers de référence, comme le $S\&P\,500$.

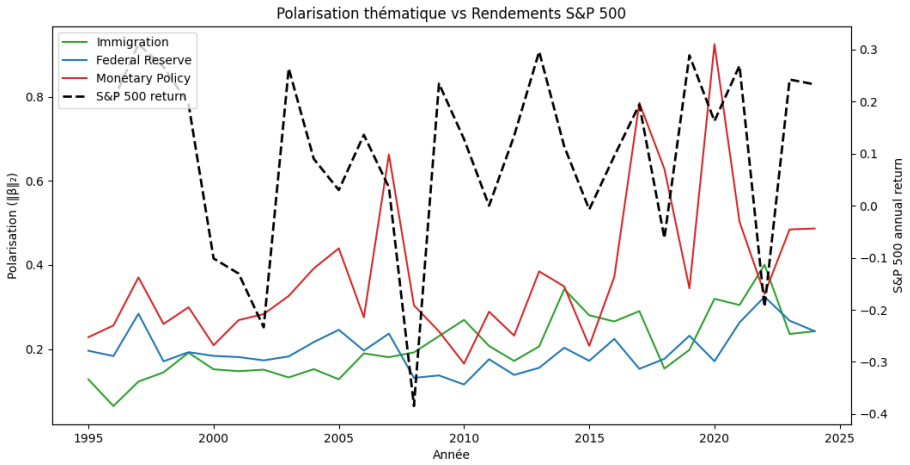

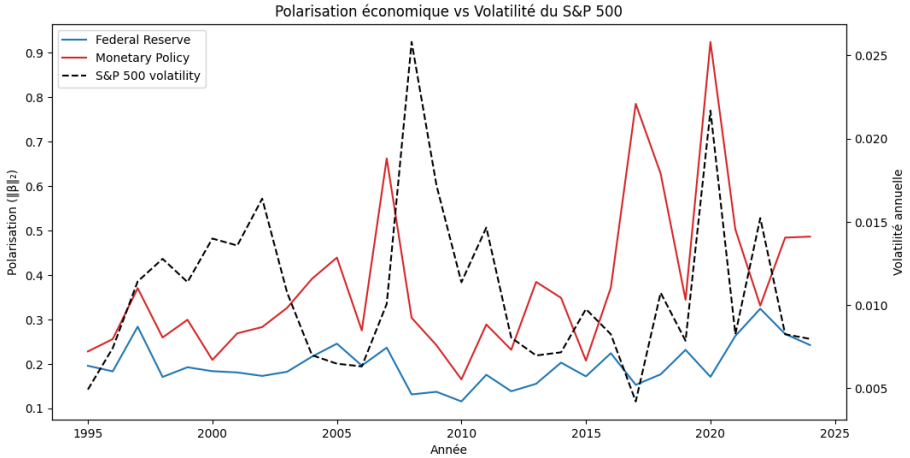

Le rendement du S&P ne semble visuellement pas corrélé avec les différentes polarisations, en revanche la **volatilité** présente une évolution qui semble plus proche, ce qui est encourageant. Après un **test de Granger** pour vérifier formellement si l'une des deux séries peut contribuer à prédire l'autre, on a les résultats suivants :

— Volatilité $\rightarrow$ Polarisation sur la politique monétaire : lag1 : $p = 0.08$; lag2 : $p = 0.11$; lag3 : $p = 0.03$
— Polarisation sur la politique monétaire $\rightarrow$ Volatilité : lag1 : $p = 0.83$; lag2 : $p = 0.56$; lag3 : $p = 0.85$
Il semble que la volatilité du marché aide à prédire la polarisation politique, l'inverse n'étant pas vrai.

Qu'en est il du lien avec le **volume du marché** ?

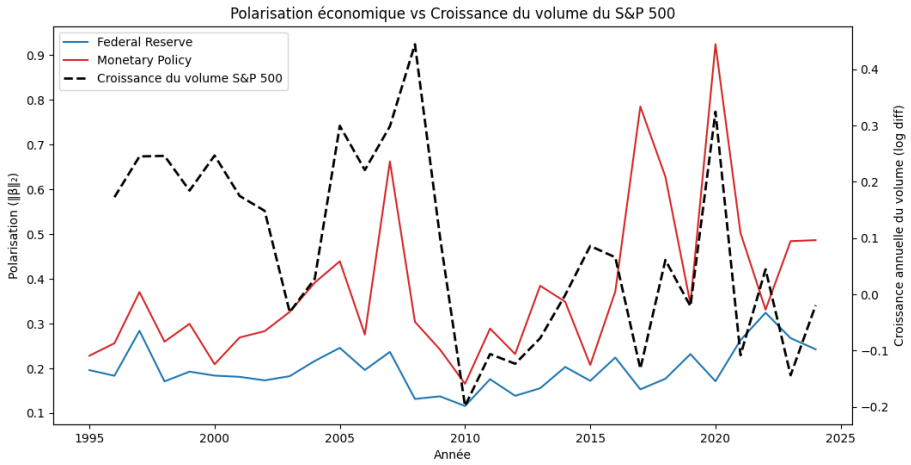

— Volume → Polarisation sur la politique monétaire : lag1 : $p = 0.2$; lag2 : $p = 0.43$; lag3 : $p = 0.08$
— Polarisation sur la politique monétaire → Volatilité : lag1 : $p = 0.90$; lag2 : $p = 0.94$; lag3 : $p = 0.91$

L'ajout du volume du marché ne semble pas apporter davantage d'information par rapport à ce qu'on avait déjà avec la volatilité. Finalement, les tensions autour de la politique monétaire ne permettent pas de connaitre avec davantage de précision l'évolution du cours du S&P, ce qui aurait pu nous intéresser, mais c'est davantage la volatilité du marché qui peut servir de variable d'alerte pour anticiper des crises politiques. Une piste reste alors à creuser dans cette idée en étudiant potentiellement d'autres mots cibles qui pourraient apporter de l'information dans l'autre sens de causalité.

3.6 Analyse locale de sentiments avec FinBERT

Enfin après avoir étudié le sens qu'attribuait les 2 partis à la Fed et aux politiques monétaires, on s'intéresse à une **analyse locale de sentiments**. On a plus besoin de la méthode ALC puisqu'**on ne va pas utiliser d'embeddings**, on va néanmoins utiliser les fonctions python qu'on a déjà écrite pour récupérer des contextes.

On va utiliser une liste d'une dizaine de mots clés autour de la politique monétaire (*inflation, taux d'intérêts*, etc), prendre 10 mots avants 10 mots après pour avoir le contexte de la phrase où le mot est utilisé. Ce contexte va constituer l'input pour FinBERT.

On va donc utiliser **FinBERT**, un Transformers basé sur l'architecture BERT et spécialisé dans le domaine financier. Il prend en entrée du texte (donc ici nos contextes) et renvoie en sortie des **probabilités de sentiment positif, neutre ou négatif**. Contrairement à BERT classique, qui fournit uniquement des représentations (embeddings) du texte, FinBERT a été fine-tuné avec une tête de classification entraînée spécifiquement pour la détection de sentiments financiers.

L'outil ne nous donnant qu'une probabilité d'affectation à ces classes, on définit une nouvelle métrique, **la polarité**, pour évaluer le **soutien** (polarité = +1) ou la **critique** (polarité = -1) :

$$\text{polarité} = P(\text{positif}) - P(\text{négatif})$$

Alors, en traçant la polarité moyenne sur ces mots clés par parti et par année :

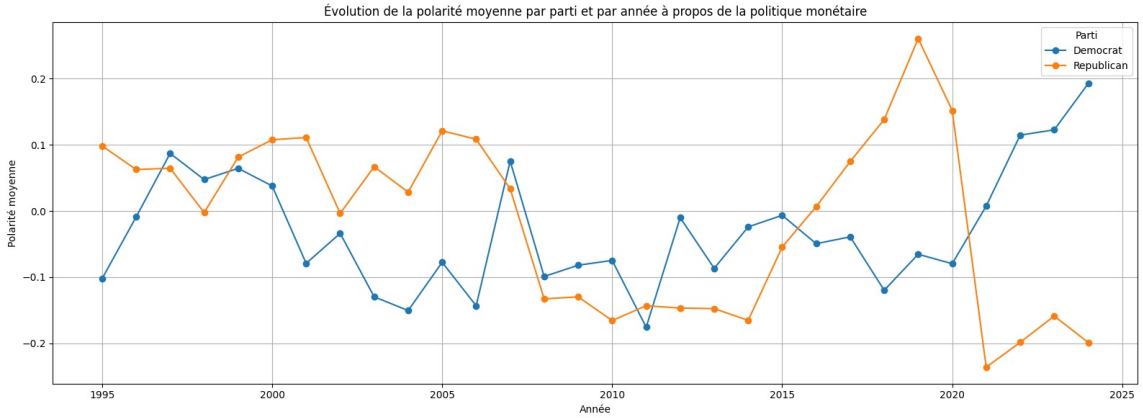

L'approche de la méthode est sûrement responsable d'avoir **bruité les résultats** en accordant pas assez d'intérêt au choix des contextes, ce qui fait une polarité moyenne proche de 0 en général, hormis pour 2018 avec un fort soutien des Républicains correspondant aux années Trump, puis une tendance opposée avec les années Biden en 2021.

3.7 Conclusion étude du Congrès

Cette étude du Congrès s'est **principalement concentrée autour de la méthode ALC**, en la recodant depuis scratch sur python et en poursuivant de nouvelles pistes là où elle montrait des limites par rapport au contexte où on voulait l'utiliser.

L'**initialisation** de la méthode a été une des étapes les plus longues car elle a demandé plusieurs choix pour pouvoir commencer à produire des embeddings qui avaient du sens, en particulier pour la décision d'inclure ou non les stopwords, la taille de la fenetre et la construction de la matrice A.

Avec davantage de temps, la **partie 5.2** aurait mérité davantage d'attention car elle constituait une application financière intéréssante, mais où la littérature propose encore **peu de ressources** comme piste d'appui.

Le **second article** introduisant un réseau de neurones a aussi été mis de côté par manque de temps car il présentait les points négatifs d'être davantage boite noire et d'avoir des résultats moins interprétables. Or bien qu'on ait tracé dans la partie 5 l'évolution de la divergence entre les 2 partis par rapport à un mot cible, le second article nous permettait d'avoir une **information supplémentaire**.
En effet sur les graphiques d'évolution de la similarité par parti, on peut aussi voir la divergence entre les 2 partis, qui serait l'aire entre les 2 courbes, mais **on sait en plus quel parti a le plus de similarité avec le mot cible**. Dans le cas de la méthode ALC, ce n'est pas visible sur le graphique car on trace seulement la distance entre les deux embeddings moyen du mot cible, on se contente juste de voir si les partis divergent ou non sur le sens accordé au mot, on ne s'intéresse pas à savoir si le mot cible est davantage associé à un parti. Par exemple lorsqu'on voit le pic en 2021 dans l'évolution temporelle de la distance pour federal reserve, on voit seulement qu'il y'a une divergence record, mais aucune distinction entre les 2 partis.

4 Conclusion

Le travail s'est divisé en 2 parties, une première partie sur l'étude des discussions de la Fed avec des méthodes de NLP avancées, l'utilisation de Transformers récents couplés à des LLM de pointe. La seconde partie a concerné l'étude des discussions du Congrès en utilisant des méthodes de NLP récentes mais avec des outils moins avancés.

Le premier projet avait pour objectif de déterminer quels membres avaient le plus d'influence à partir des transcripts de la FOCM. Pour cela, 2 méthodes ont été employées, la première consiste à utiliser Mistral pour résumer les longues prises de parole, puis SBERT pour les vectoriser. La seconde méthode utilise doc2vec pour vectoriser toutes les prises de parole.

On obtient bien un classement pertinent des personnes les plus influentes avec les 2 méthodes, or bien que la première demande plus de 50h de calcul contre 5 minutes pour l'autre, aucun des 2 classements ne domine l'autre et apparait comme absolu.

Un travail pourrait être fait sur trouver une relation de comparaison entre 2 classements, afin de construire au fur et à mesure par recherche d'hyperparamètres ou d'autres méthodes un classement optimal. La dimenson subjective de l'influence demande une forte normalisation de ce qu'on attend et d'à quel moment ce qu'on obtient est satisfaisant pour définir plus rigoureusement le projet.

Le second projet avait lui pour objectif de déterminer quel sens les Républicains et les Démocrates associaient à la politique monétaire. Pour cela, on s'est essentiellement concentré sur la méthode ALC.

On a alors pu vérifier quel sens était associé aux sujets de la Fed et de la politique monétaire, étudier la divergence entre les 2 partis et son évolution au fil du temps, ainsi que leur support ou non à ces sujets. Les résultats obtenus dans cette partie sont bien plus interprétables que ceux du premier sujet, que ce soit dans leur construction ou leur lecture.

Une piste intéréssante encore à creuser est le prolongement de l'étude de corrélation entre indices boursiers et polarisation politique, constituant une application financière qui vaudrait le coup d'être interrogé avec des outils plus récents que ceux de la méthode ALC, la prédiction du cours du S&P étant un sujet particulièrement d'actualité.

5 Bibliographie

Articles pour le premier projet

— Adrien Letellier, Alessandro Riboni, Francisco Ruge-Murcia, 2024. *Speech and Influence Dynamics in a Monetary Committee*

— Katharina Lix, Amir Goldberg, Sameer B. Srivastava, Melissa A. Valentine, 2022. *Aligning Differences : Discursive Diversity and Team Performance*

— Alexander T. J. Barron, Jenny Huang, Rebecca L. Spang, Simon DeDeo, 2018. *Individuals, Institutions, and Innovation in the Debates of the French Revolution*

— Carlos López Pérez, Humberto Llinás Solano, 2025 *A Comprehensive Guide to Latent Dirichlet Allocation : Building a Solid Foundation with Key Statistical Concepts*

— Bryan Kelly, Dimitris Papanikolaou, Amit Seru, Matt Taddy, 2020 *Measuring Technological Innovation over the Long Run*

— Agam Shah, Suvan Paturi, Sudheer Chava, 2023 *Trillion Dollar Words : A New Financial Dataset, Task & Market Analysis*

— Kwok Ping Tsang, Zichao Yang, 2025 *Agree to Disagree : Measuring Hidden Dissent in FOMC Meetings*

Articles pour le second projet

— Pedro L. Rodriguez, Arthur Spirling, Brandon M. Stewart. 2022. *Embedding Regression : Models for Context-Specific Description and Inference.*

— Ludovic Rheault, Christopher Cochrane. 2019. *Word Embeddings for the Analysis of Ideological Placement in Parliamentary Corpora.*

— Mikhail Khodak, Nikunj Saunshi, Yingyu Liang, Tengyu Ma, Brandon Stewart, Sanjeev Arora. 2018. *A La Carte Embedding : Cheap but Effective Induction of Semantic Feature Vectors.*

— Arnav Hiray, Yunsong Liu, Mingxiao Song, Agam Shah, Sudheer Chava. 2024. *CoCoHD : Congress Committee Hearing Dataset.*

— Vincent Enoasmo, Cedric Featherstonehaugh, Xavier Konstantinopoulos, Zacharias Huntington. 2025. *Structural Embedding Projection for Contextual Large Language Model Inference.*

— Pedro L. Rodriguez, Arthur Spirling, 2022. *Word Embeddings : What works, what doesn't, and how to tell the difference for applied research.*

6 Annexes

Politique monétaire

Différence Hawkish vs Dovish : ce sont 2 termes utilisés en politique monétaire pour décrire l'attitude ou l'orientation des banques centrales vis à vis de l'inflation, des taux d'intérêts et de la croissance économique.

Hawkish (faucon) : la BC est préoccupée par l'inflation et veut augmenter les taux d'intérêts pour la maitriser, même si cela freine la croissance et l'emploi. Objectif : réduire l'inflation et préserver la stabilité des prix. Csq : renforcement de la monnaie et baisse potentielle des marchés d'actions.

Dovish (colombe) : la BC est préoccupée par la croissance ou le chomage, et veut baisser les taux d'intérêts pour soutenir l'activité économique. Objectif : stimuler l'économie, augmenter la création d'emplois et relancer la demande. Csq : afaiblissement de la monnaie et hausse potentielle des marchés d'actions.

Augmenter les taux d'intérêts revient à freiner l'inflation : quand les prix augmentent trop vite, la BC monte les taux pour ralentir la demande, ça réduit la consommation et l'investissement car les crédits deviennent plus cher, ça encourage l'épargne et stabilise la monnaie. Risque de ralentir excessivement l'économie (recession), d'augmenter le chomage et d'alourdir la charge de la dette publique.

Baisser les taux d'intérêts revient à stimulater la croissance économique : quand l'économie est en difficulté (faible croissance, chomage élevé), la BC baisse les taux pour relancer la demande, les crédits sont moins chers donc plus de consommation et les entreprises embauchent plus. Risque de favoriser un endettement excessif, de créer des bulles spéculatives, de réduire la rentabilité de l'épargne et de nourrir l'inflation à long terme.

Méthode TF-IDF

La méthode TF-IDF permet de quantifier l'importance d'un mot dans un texte, relativement à un ensemble de documents.

On a d'abord TF (Term Frequency) qui mesure la fréquence d'apparition du mot dans le texte, puis IDF qui pénalise les mots fréquences dans l'ensemble du corpus en leur attribuant un poids plus faible.

Avec TFxIDF, on attribue donc plus de valeur aux mots caractéristiques d'un document mais peu communs ailleurs.

La méthode est simple à calculer, rapide et efficace pour des tâches de recherche d'information, de classification de texte ou de résumé automatique. Elle ne nécessite aucun entrainement ni données annotées.

En revanche elle ne capte pas le contexte ou le sens des mots, elle ignore l'ordre des mots et la structure grammaticale. Elle est censé être moins performante que des modèles modernes (word2vec ou BERT) pour des tâches complexes.

Hypothèses Régression Linéaire

1. **Linéarité** : la relation entre les variables explicatives et la variable expliquée est linéaire dans les paramètres, soit $Y = X\beta + \varepsilon$.
2. **Exogénéité** : l'espérance du terme d'erreur conditionnellement aux variables explicatives est nulle, soit $E[\varepsilon|X] = 0$.

3. **Homoscédasticité** : la variance du terme d'erreur est constante, soit $\mathrm{Var}(\varepsilon|X) = \sigma^2$.
4. **Indépendance des erreurs** : les erreurs ne sont pas autocorrélées, soit $\mathrm{Cov}(\varepsilon_i, \varepsilon_j|X) = 0$ pour $i \neq j$.
5. **Absence de colinéarité parfaite** : les variables explicatives ne sont pas linéairement dépendantes, ce qui garantit que la matrice $X^\top X$ est inversible.
6. **Normalité des erreurs** (optionnelle) : les erreurs suivent une loi normale conditionnellement à X, soit $\varepsilon \sim \mathcal{N}(0, \sigma^2)$.